Chapter 1. Kick-off & Agent 패러다임

Chapter 1. Kick-off & Agent 패러다임

> **학습 목표**
>
> - ◯ LLM의 동작 원리(토큰 예측, 디코딩)와 4가지 시스템적 한계를 설명할 수 있다
> - ◯ ReAct 패턴(Thought → Action → Observation)으로 Agent가 LLM 한계를 극복하는 방식을 설명할 수 있다
> - ◯ Framework(LangChain) → Runtime(LangGraph) → Harness(DeepAgents) 3계층의 역할을 비교할 수 있다
> - ◯ 작업 복잡도에 따라 단순 LLM 호출부터 Agent까지 적합한 패턴을 구분할 수 있다

소요시간	학습방법
1.0h	이론

⏱ 09:00 – 시작

0. 왜 지금 Agent인가? — Phase Shift

Karpathy의 선언 (2025년 12월)

Andrej Karpathy — Tesla 자율주행 AI 총괄 출신, OpenAI 창립 연구팀 멤버 — 는 2025년을 AI가 **능력 임계점을 넘은 해**로 평가했습니다.

"2025년은 AI가 단순히 영어로만 지시해도 온갖 인상적인 프로그램을 만들어낼 수 있는 역량 임계점을 넘어선 해이며, 이제는 코드라는 것이 존재한다는 사실조차 잊게 되는 해다."

> *"2025 is the year that AI crossed a capability threshold necessary to build all kinds of impressive programs simply via English, forgetting that the code even exists."*
> — Andrej Karpathy, 2025 Year in Review

이 임계점이 **Agent 영역**에서 구체적으로 어떻게 나타났는지, 수치로 확인해보겠습니다.

수치로 보는 변화 — Agent가 실제 엔지니어링 문제를 푼다

SWE-Bench Verified — Princeton NLP 팀이 만든 소프트웨어 엔지니어링 벤치마크입니다. 실제 오픈소스 GitHub 이슈(Django, scikit-learn 등 12개 라이브러리)를 주고, 코드를 읽고 → 버그를 찾고 → 패치를 작성하고 → 테스트를 통과해야 합니다. Verified 서브셋은 500문제를 93명의 개발자가 교차 검증한 고품질 부분집합입니다.

성능 변화 추이 (Verified 기준, swebench.com 2026-02 스냅샷):

시점	최고 성능	대표 시스템
2024년 초	~14%*	Devin (Cognition AI)
2024년 말	~49%	Claude 3.5 Sonnet 기반
2025년 초	~62%	Claude 3.7 Sonnet
2025년 중	~70%	Claude 4 계열
2026년 초	**76.8%**	**Claude 4.5 Opus** (mini-SWE-agent v2 기준 1위)

> *2024년 초 Devin의 수치는 Verified 이전의 Full SWE-Bench(2,294문제) 기준. 이후 행은 모두 Verified 기준입니다. 수치는 리더보드 상위 시스템 스냅샷이며, 최신 값은 swebench.com에서 확인하세요.

SWE-bench

Leaderboards

BENCHMARKS

SWE-bench

SWE-bench Verified

SWE-bench Multilingual

SWE-bench Multimodal

SWE-bench Lite

ABOUT

Paper

Docs

Blog

Contact

Citations

Press

Submit

SWE-BENCH FAMILY

mini-SWE-agent

SWE-smith

CodeClash

SWE-ReX

SWE-bench CLI

SWE-agent (legacy)

Official Leaderboards

There's an all-new, challenging SWE-bench **Multimodal**, containing software issues described with images.
Learn more here.

Verified | Multilingual | Lite | Full | Multimodal

Verified is a human-filtered subset of 500 instances. We use mini-SWE-agent to evaluate all models with the same harness (details).

Compare results | Agent: mini-SWE-agent v2 | Models: All models

Model	% Resolved	Avg. $	Trajs	Org	Date	Agent
Claude 4.5 Opus (high reasoning)	76.80	$0.75			2026-02-17	2.0.0
Gemini 3 Flash (high reasoning)	75.80	$0.36			2026-02-17	2.0.0
MiniMax M2.5 (high reasoning)	75.80	$0.07			2026-02-17	2.0.0
Claude Opus 4.6	75.60	$0.55			2026-02-17	2.0.0
GPT-5-2 Codex	72.80	$0.45			2026-02-19	2.0.0
GLM-5 (high reasoning)	72.80	$0.53			2026-02-17	2.0.0
GPT-5-2 (high reasoning)	72.80	$0.47			2026-02-17	2.0.0
GPT 5.2 Codex	72.80	$0.45			2026-02-19	2.0.0
Claude 4.5 Sonnet (high reasoning)	71.40	$0.66			2026-02-17	2.0.0
Kimi K2.5 (high reasoning)	70.80	$0.15			2026-02-17	2.0.0
DeepSeek V3.2 (high reasoning)	70.00	$0.45			2026-02-17	2.0.0
Gemini 3 Pro	69.60	$0.96			2026-02-26	2.0.0
Claude 4.5 Haiku (high reasoning)	66.60	$0.33			2026-02-17	2.0.0
GPT-5 Mini	56.20	$0.05			2026-02-17	2.0.0

SWE-bench **Verified** is a human-filtered subset of 500 instances; use the Agent dropdown to compare LMs with mini-SWE-agent or view all agents [Post].
SWE-bench **Multilingual** features 300 tasks across 9 programming languages [Post].

SWE-bench Verified 리더보드 (2026-03 스냅샷, mini-SWE-agent v2 기준). Claude 4.5 Opus 76.8%, Gemini 3 Flash 75.8%, Claude Opus 4.6 75.6% 순.

> **이 교재를 쓰는 동안에도 세상은 바뀌고 있습니다.** 위 표를 작성한 2026년 2월 기준 Claude 4.5 Opus가 정상이었지만, 불과 수주 만에 **GPT-5.4**(OpenAI)와 **Claude Opus 4.6**(Anthropic)이 새로 출시되었습니다. 리더보드 상위 10개 모델이 70~77% 대에 밀집해 있어, 이제는 **모델 단독 성능보다 Agent Harness(실행 환경)의 설계가 순위를 좌우**하는 구간에 진입했습니다.

현장의 변화

Karpathy의 경험 (X, 2026-01): **"80% 수동+자동완성, 20% Agent" → "80% Agent 코딩, 20% 수정·터치업"** (2025년 11→12월 변화)

- 반복적 코딩 작업의 대부분을 Agent가 처리
- 개발자 역할: 코드 작성자 → **편집자·검토자(Editor/Reviewer)**
- 새로운 병목: 지능(Intelligence) 문제는 해결 → 통합(Integration), 조직(Workflow) 문제로 이동

이 변화는 코딩에만 국한되지 않습니다. "Agent가 코드를 잘 짠다"에서 시작된 역량이 **이메일 관리, 문서 처리, 브라우저 자동화 등 일반 업무 전반**으로 확산되고 있습니다. 아래 제품들이 그 예입니다.

Phase Shift가 낳은 제품들 (2026년 1~2월)

이 변화를 가장 빠르게 체감할 수 있는 곳은 오픈소스 커뮤니티와 제품 시장이었습니다.

제품	출시	설명
OpenClaw	2025-11	오픈소스 자율 AI Agent. 이메일·캘린더·터미널을 LLM으로 제어. 2026-01 리브랜딩 후 **10일 만에 GitHub Stars 210K** 돌파 — 역대 가장 빠른 성장.
Claude Cowork	2026-01	Anthropic의 범용 AI Agent. *"Claude Code for the rest of your work"*. macOS에서 파일 관리·문서 처리·브라우저 자동화를 자율 실행. Max 구독자 대상으로 시작, **4일 만에 Pro($20/월)로 확대**.

두 제품의 공통점은 단순 챗봇이 아니라 **다단계 작업을 스스로 계획하고 실행하는 Agent Harness** 구조라는 점입니다. Ch3에서 실습할 DeepAgents도 같은 계층에 해당합니다.

이런 Agent Harness가 어떻게 동작하는지 이해하려면, 먼저 그 핵심 엔진인 **LLM이 무엇이고 어떤 한계가 있는지** 알아야 합니다. Agent는 LLM의 한계를 극복하기 위해 존재하고, Harness는 그 Agent를 안정적으로 운영하기 위해 존재하기 때문입니다.

⏱ 09:08

1. LLM 동작 방식 복습

1.1 LLM의 본질: 다음 토큰 예측기

LLM(Large Language Model)의 핵심 동작은 한 문장으로 요약됩니다.

> **"지금까지의 텍스트를 보고, 다음에 올 토큰을 예측한다."**

```
입력: "오늘 서울의 날씨는"
    ↓ [확률 분포 계산]
출력: "맑습니다" (p=0.42), "흐립니다" (p=0.31), "좋습니다" (p=0.18), ...
```

메커니즘 자체는 단순하지만, **학습 데이터·파라미터·연산량을 수천억 규모로 키우면** 학습 과정에서 예상하지 못한 능력이 나타납니다. 이를 **창발적 능력(Emergent Abilities)** 이라 부릅니다.

- 논리적 추론 (Chain-of-Thought)
- 코드 생성 및 디버깅
- 다국어 번역
- 수학적 계산

> **학술 균형 메모**: 창발적 능력은 널리 쓰이는 설명이지만, Schaeffer et al. (2023)은 일부 현상이 평가 메트릭의 비선형성에서 오는 "착시"일 수 있다고 반박합니다. 본 과정에서는 "창발은 관측되는 현상"으로 다루되, 해석에는 논쟁이 있음을 전제로 합니다.

1.2 LLM 내부는 어떻게 생겼나? — Karpathy의 microGPT

> *"GPT를 243줄 순수 Python으로 구현할 수 있다."* (번역·의역)
> — Andrej Karpathy, 2026년 2월 (microGPT)

Karpathy는 GPT의 핵심 구조를 라이브러리 없이 약 243줄로 구현했습니다. 243줄이라는 코드 길이가 아니라, 그 코드가 드러내는 **동작 원리**가 핵심입니다. LLM은 입력 토큰들의 통계적 관계를 학습한 가중치를 바탕으로 다음 토큰을 예측할 뿐, 사실을 "알고" 답하는 것이 아닙니다. 이 특성이 아래에서 다룰 Hallucination의 근본 원인이자, Agent가 필요한 이유입니다.

LLM의 핵심 부품 3가지

Agent 개발자가 알아야 할 LLM의 핵심 구조는 세 가지입니다.

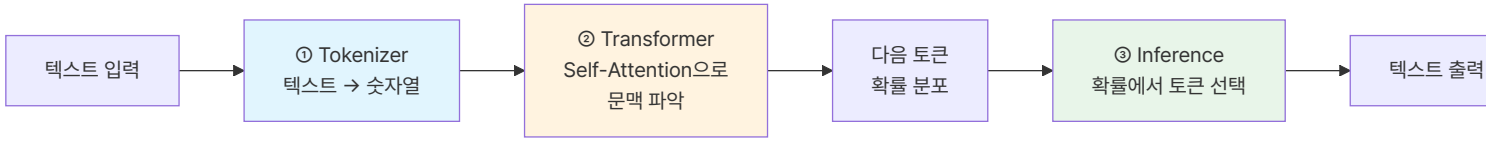

① Tokenizer — 텍스트를 숫자로 변환합니다. GPT/Claude는 BPE 방식(자주 붙는 조합을 하나의 토큰으로 묶어 효율 향상)을 씁니다.

② Transformer — 각 토큰이 다른 토큰들을 얼마나 참고할지 계산하는 **Self-Attention**이 핵심입니다.

```
"팀장님이 회의를 취소했다"

  "취소했다"는 주어가 필요 → 모든 토큰과 관련도 계산
  → "팀장님"에 높은 가중치 부여 → 주어 파악
```

이 과정(수조 개 텍스트로 수십억 번 반복 학습)을 통해 언어의 통계 패턴이 가중치에 압축됩니다.

③ Inference — 학습된 가중치로 "다음 토큰의 확률 분포"를 출력하고, 그 분포에서 하나를 뽑습니다.

```
"한국의 수도는" → Transformer 계산 → "서울"(0.97), "부산"(0.01), ... → 샘플링 → "서울"
```

> **심화**: 학습 과정(역전파/옵티마이저)과 Attention 수학(Q·K·V)이 궁금하다면 microGPT 전체 코드를 참고하세요.

⏱ 09:15

디코딩 전략 — "왜 LLM은 매번 다른 답을 내는가?"

확률 분포에서 **어떤 토큰을 고를지**는 디코딩 전략이 결정합니다. 상용 API에서 직접 조절하는 파라미터는 **Temperature**와 **Top-p** 두 가지입니다.

```
확률 분포 예시: "오늘 날씨가" 다음 토큰

  확률
  0.4 ┤ ▇
  0.3 ┤ ▇  ▇
  0.2 ┤ ▇  ▇
  0.1 ┤ ▇  ▇  ▇  ▇
  0.0 ┤ ▇  ▇  ▇  ▇  ▇  ▇
      └맑──흐──좋──추──화──기── ...
        습  립  습  웠  창  대
        니  니  니  습  합  됩
        다  다  다  니  니  니
                    다  다  다

  ← temperature 낮으면 "맑습니다"에 집중 (결정론적)
  → temperature 높으면 분포가 평탄해져 다양한 토큰 선택 (확률적)
```

전략	방식	API 파라미터
Temperature	분포를 날카롭게(→결정론적) / 부드럽게(→다양성) 조절 후 샘플링	`temperature=0~2`
Top-p (Nucleus)	누적 확률 p까지의 후보만 남기고 그 안에서 샘플링	`top_p=0~1`

> **직접 실험해 볼까요? (5분)**
>
> `code/ch1-llm-basics/llm_experiment.ipynb` 의 **실험 1**과 **실험 2**를 열어보세요. 실험 1에서는 `logprobs` 로 LLM이 각 토큰 위치에서 고려한 후보와 확률을 직접 확인합니다. 실험 2에서는 temperature를 바꿔가며 같은 질문에 다른 답이 나오는지 관찰합니다.

> `temperature=0` ≈ **Greedy, 하지만 완전한 결정론은 아닙니다.**
> 학술 문헌의 Greedy Decoding(최고 확률 토큰만 선택)이나 Beam Search(상위 k개 경로 병렬 탐색)는 상용 API에서 직접 노출되지 않으며, `temperature=0` 이 사실상 Greedy와 동일한 효과를 냅니다. 그러나 **동일 입력이라도 미세하게 다른 결과가 나올 수 있습니다.**
>
> - **부동소수점 비결합성**: GPU 병렬 연산의 덧셈 순서 변동 → 반올림 오차로 확률 순위가 뒤바뀜
> - **배치 크기 변동**: 서버 부하에 따라 GPU 커널의 reduction 전략이 달라짐 (Thinking Machines Lab, 2025)
> - **MoE 라우팅 경쟁**: Mixture-of-Experts 아키텍처에서 토큰이 어느 전문가에게 할당될지가 배치 내 경쟁으로 결정됨
>
> OpenAI: *"Determinism is not guaranteed"* (Cookbook). Anthropic: *"Even with temperature set to 0, the results will not be fully deterministic"* (Glossary). 프로덕션에서는 출력 검증 로직을 별도로 설계해야 합니다.

```
입력: "오늘 날씨가"

temperature=0   → "맑습니다." (대부분 동일하나, 드물게 달라질 수 있음)
temperature=1.0 → "맑고 따뜻합니다." or "흐릴 것 같네요."    (적당한 다양성)
temperature=2.0 → "눈부시게 황홀한 하늘빛이군요!"            (오류 위험 ↑)
```

생각해보기 (30초)

LLM이 "다음 토큰 예측기"라면, **"오늘 달러/원 환율은?"** 이라는 질문에 정확히 답할 수 있을까요? 그 이유는 무엇일까요?
먼저 직접 생각한 뒤, 아래 정답을 확인하세요.

생각 정리: 답할 수 없습니다. LLM의 가중치는 학습 시점의 통계 패턴만 담고 있어, 실시간 데이터(환율, 주가, 날씨)에는 접근할 방법이 없습니다. 이것이 바로 아래에서 다룰 Hallucination의 근본 원인이며, 나아가 Agent가 필요한 이유입니다.

왜 이것이 중요한가?

```
"한국의 수도는" → "서울" (p=0.97)      ✅ 학습 패턴 = 현실
"오늘 달러/원 환율은" → 실시간 값 없음  ❌ 학습 패턴 ≠ 현실 → 환각
```

Hallucination의 정체: 모델은 진실의 개념이 없습니다. 가중치에 압축된 통계 패턴이 현실과 일치할 때만 사실처럼 보일 뿐입니다.

실무에서는 두 가지로 구분합니다.

- **Faithfulness hallucination**: 입력/Tool 결과와 모순되는 출력 — Agent에서 특히 치명적
- **Factuality hallucination**: 외부 현실 사실과 모순되는 출력

프로덕션에서는 근거가 불충분하면 답변을 보류(abstention)하는 정책이 기본입니다.

그렇다면 이 환각은 왜 불가피한 것일까요? 1.2절에서 본 것처럼, microGPT든 GPT-4든 핵심 원리는 동일합니다: **Tokenize → Attend → Predict**. 규모가 커져도 이 구조 자체가 바뀌지 않기 때문에, 환각은 모델 크기와 무관한 **구조적 현상**입니다.

Agent의 Tool Use는 **Factuality hallucination**(외부 사실과 다른 출력)을 크게 줄일 수 있습니다. 그러나 Tool이 정확한 데이터를 반환해도 모델이 이를 무시하거나 왜곡하는 **Faithfulness hallucination**은 별도로 관리해야 합니다. 따라서 프로덕션 Agent에서는 Tool Use + 검증 레이어 + 답변 보류(abstention) 정책을 조합합니다.

참고: 환각의 근본 원인

> Kalai et al. (2025, "Why Language Models Hallucinate")은 환각이 단순한 버그가 아니라 **훈련·평가 구조 자체가 추측을 장려하기 때문**이라고 밝혔습니다. 벤치마크가 이진 채점(맞으면 1점, "모르겠다"도 0점)을 사용하므로, 모델은 불확실해도 자신 있게 추측하도록 학습됩니다. Xu et al. (2025)은 환각이 LLM의 본질적 한계임을 수학적으로 증명했습니다.

세부 정보

툴 스키마를 지정하면 시스템 프롬프트에 JSON 형태를 포함하지 않아도 된다. create_react_agent는 자동으로 툴 설명을 포함하고, 최종 출력 형상을 pydantic 또는 JSON 스키마로 강제할 수 있다.

구현 중 도구 적재

다양한 도구를 MultiServerMCPClient로 연결하고 있으며, structured output을 사용해 명령을 구조화하여 정리하고 있어.

도구 호출 관리

request_human_approval 도구를 구현하면서, WebSocket 대신 interrupt를 활용해 허가 독립적인 인터페이스를 구성하고 있어.

검토 중임

JavaScript의 entrypoint와 동일한 개념을 다루고 있어. Python 문서에서는 create_react_agent 및 interrupt_before와 관련된 부분을 살펴보고 있어.

Stream 처리와 실제 시간 제어

Http POST /api/trade에서 graph.stream()으로 스트림을 처리하고, 중단과 승인 후 재개하는 방식 로 이동하고 있어.

가정 탐색하기

내가 살고 있는 집 주변을 걸어 보니, 낯익은 집들이 눈에 띄고 있네. 집마다 꽃밭이 아름답고 사람들이 정원을 가꾸고 있네. 기분이 좋아지고 이 아름다움을 감사하게 여겨.

소풍 지나기

아이들과 함께 소풍을 떠나고 있어. 푸른 하늘 아래 펼쳐진 잔디밭에서 놀고, 맛있는 도시락을 먹으니 행복이 넘쳐나고 있어.

고양이와 시간 보내기

부엌에서 요리하는 동안 고양이가 내발에 옹기종기 앉아 있어. 부드러운 털을 자주 쓰다듬어 주고 있어. 이 부드러운 순간들이 정말 소중해.

도구 함수 설명

분석 및 뉴스 가져오기 도구를 다루고 있어. 요청 승인 도구는 외부 호출을 중지하고, 앱에서 사용자 승인 확인 후 다음 단계로 넘어가고 있어.

활성화된 도구 평가
도구 호출을 위한 request_human_approval 도구를 평가하고 있어. 승인되지 않으면 execute_trade 호출을 중단하고 있어. request_human_approval은 중단 이벤트로 작동 중이야.

작동하는 구조 살펴보기

create_react_agent의 전환을 고려하고 있어. interrupt_before=['tools']를 활용해 도구 실행 직전과 직후를 관리하고, AI 메시지 상태를 조정하여 도구 실행을 조절 중이야.

편집하고 있어

그래프 상태를 보고 있는 중이야.

명령어 사용하기
Command python으로 그래프 상태를 바꾸고 있어요.

제작자 조정

커스텀 작지만 복잡한 LangGraph를 설계하고 있어. Node "agent"는 ChatOpenAI로 도구를 활용 중이야.

효과적으로 구현하기
request_human_approval을 interrupt로 구현하고, UI 이벤트를 외부에서 처리하며 JSON을 반환하는 중입니다.

⏱ 09:22

1.3 LLM의 4가지 시스템적 한계

Hallucination은 LLM의 한계 중 하나입니다. Agent를 설계하려면 이것 외에도 반드시 알아야 할 구조적 한계가 세 가지 더 있습니다.

#	한계	설명	실제 영향	Agent 해결책
1	**Stateless**	이전 대화를 기억하지 못함. 모델 자체는 stateless며, 앱이 히스토리를 매번 재주입해 "기억하는 것처럼" 구현	매 요청마다 전체 컨텍스트를 다시 전달해야 함	Checkpointer로 세션 간 상태 유지

#	한계	설명	실제 영향	Agent 해결책
2	**Context Window**	한 번에 처리할 수 있는 정보량 제한	대규모 코드베이스, 긴 문서는 한 번에 처리 불가	Filesystem Backend로 컨텍스트 밖 저장, Skills의 Progressive Loading (필요한 지침만 단계적 로드, Ch4)
3	**Hallucination**	통계적 패턴이 현실과 다름 (1.2절 참고)	신뢰 불가 → 외부 검증 필수	Tool Use로 실제 데이터 조회·검증
4	**Knowledge Cutoff**	학습 시점 이후 정보를 모름	실시간 정보 접근 불가	실시간 검색/API Tool 연결

```
# 개념 예시 (의사코드) — 실행 코드는 Ch2 Step 1에서 작성합니다
# ❌ Stateless 문제 — LLM은 이전 대화를 기억 못함
response1 = llm("제 이름은 김철수입니다.")
response2 = llm("제 이름이 뭐였죠?")  # → 대답 불가!

# ✅ 해결: 대화 기록을 직접 관리하여 매번 전달
history = [
    {"role": "user", "content": "제 이름은 김철수입니다."},
    {"role": "assistant", "content": "안녕하세요 김철수님!"},
]
response = llm(history + [{"role": "user", "content": "제 이름이 뭐였죠?"}])
# → "김철수님이라고 하셨습니다."
```

→ 이 한계를 극복하기 위한 시스템이 바로 **Agent**입니다.

⑦ 체크포인트 1 (1분)

LLM의 4가지 한계와 Agent가 제공하는 해결책을 연결해보세요.

LLM 한계	Agent 해결책은?
Stateless	???
Context Window	???
Hallucination	???
Knowledge Cutoff	???

먼저 직접 생각한 뒤, 아래 정답을 확인하세요.

정답:

- **Stateless** → 대화 히스토리를 매번 전달하여 상태를 유지합니다. Ch2에서 배울 Checkpointer가 이를 자동화합니다.
- **Context Window** → Filesystem Backend로 컨텍스트 밖에 데이터를 저장/로드합니다.
- **Hallucination** → Tool Use로 외부 데이터를 조회하여 Factuality hallucination을 줄입니다. 단, Tool이 정확한 정보를 줘도 모델이 왜곡할 수 있는 Faithfulness hallucination은 별도 검증이 필요합니다.
- **Knowledge Cutoff** → 실시간 검색/API Tool을 연결합니다.

⏱ 09:27

2. "Agent"란? — ReAct & Tool 사용 개념

이 교재에서 Agent는 "LLM+Tool"을 넘어, **부분 관측 환경에서 Observation → Belief Update → Action 루프를 반복하며 목표를 달성하는 폐루프 의사결정 시스템**으로 정의합니다.

2.1 ReAct 패턴: Thought → Action → Observation

2022년 Yao et al.의 **ReAct(Reason + Act)** 가 현대 Agent 루프의 기초를 제시했고, ICLR 2023에 정식 게재되었습니다 (Princeton + Google Research/Brain team).

Agent는 단순히 "답변"을 생성하는 것이 아니라, **생각하고(Thought) → 행동하고(Action) → 관찰(Observation)하는 루프**를 반복합니다.

실습에서는 내부 Thought를 직접 출력하지 않고, 다음 신호로 ReAct 단계를 확인합니다.

- Thought(추론): Tool 호출 직전 assistant 메시지의 의도/계획 문맥
- Action(행동): `tool_calls` 이벤트 (도구명/인자)
- Observation(관찰): `ToolMessage` 또는 tool result payload

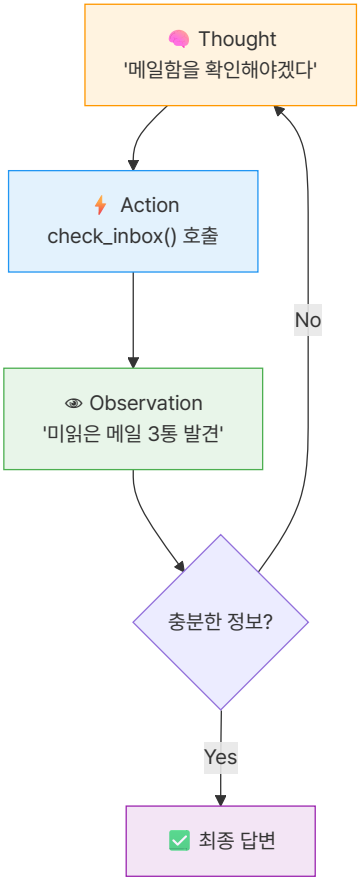

> **참고**: ReAct 외에 Reflexion(자기 반성 루프), Plan-and-Execute(계획 후 실행 분리) 등의 Agent 패턴도 연구되었으나, 현재 상용 프레임워크(LangGraph, OpenAI Agents SDK 등)의 기본 구조는 대부분 **ReAct 또는 그 변형**입니다. 본 과정에서도 ReAct를 기본으로 다룹니다.

2.2 예시: 전통적 LLM vs Agent

```
# 개념 예시 (의사코드) - 실행 코드는 Ch2 Step 2에서 작성합니다
# ❌ 전통적 LLM - 실시간 정보 접근 불가
response = llm("내 메일함에 중요한 메일이 있나요?")
# → "죄송하지만, 저는 귀하의 메일에 접근할 수 없습니다..."

# ✅ Agent (ReAct 패턴) - Tool을 사용하여 실제 작업 수행
# Thought: 메일함을 확인하려면 mail API를 호출해야 한다
action_result = check_inbox(filter="unread")
# Observation: [{"from": "팀장님", "subject": "긴급: 서버 점검"}, ...]

# Thought: 긴급 메일이 있으니 사용자에게 알려야 한다
final = llm(f"관찰 결과: {action_result}\n→ 사용자에게 요약해주세요")
# → "긴급 메일이 1통 있습니다. 팀장님이 보낸 '서버 점검' 관련입니다."
```

2.3 Agent의 핵심 구성요소

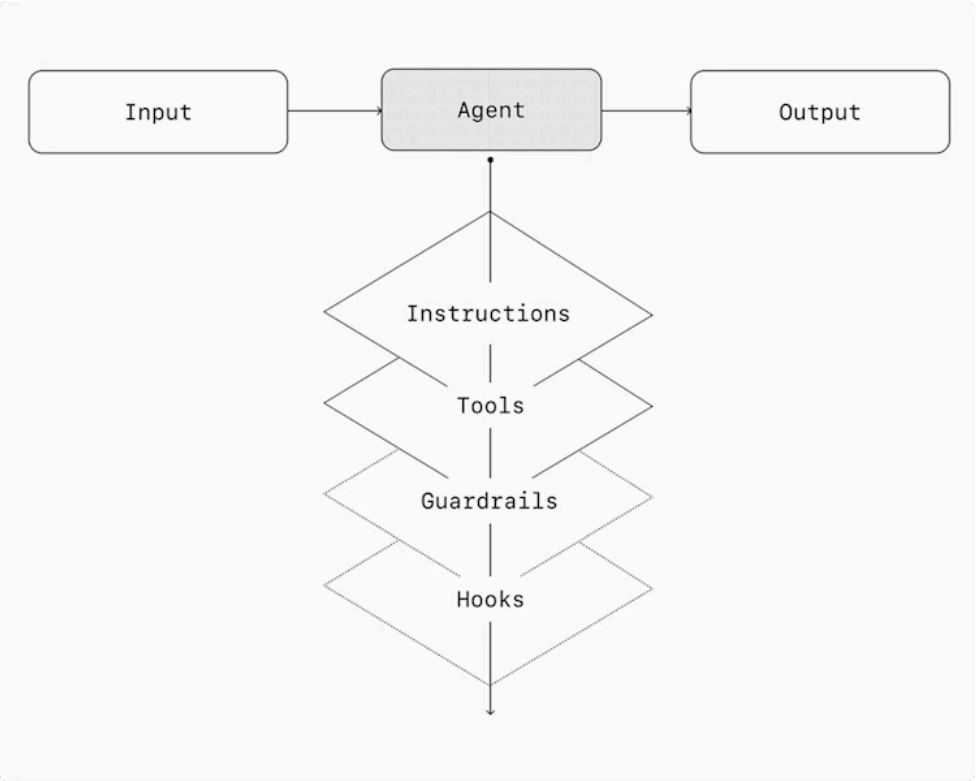

OpenAI는 "A Practical Guide to Building Agents" (2025)에서 Agent를 **Model + Instructions + Tools**의 3요소로 정의합니다. Google의 Agents Whitepaper(2024)는 **Model + Orchestration + Tools**의 3계층을, Lilian Weng(OpenAI Research Lead)은 **LLM(두뇌) + Planning + Memory + Tool Use**의 구조를 제시합니다. 소스마다 분류가 다르지만, 실무에서 공통으로 등장하는 핵심 구성요소를 정리하면 다음과 같습니다.

구성요소	역할	없으면?	예시
Model (Reasoning)	상황 분석, 다음 행동 판단, 계획 수립 — Agent의 두뇌	도구 선택, 계획 수립, 결과 평가 등 의사결정 불가	GPT, Claude, Gemini
Instructions	Agent의 목적, 행동 범위, 가드레일을 정의	방향 없이 표류 — 어떤 도구를 쓸지, 어떤 톤으로 답할지 결정 불가	System prompt, SKILL.md
Tools	외부 시스템과 상호작용하는 수단	"생각만 하는 존재"에 머묾, 실제 행동 불가	API 호출, 파일 읽기/쓰기, DB 조회
Memory	단기(현재 대화) + 장기(과거 경험) 기억	매 턴마다 처음부터 시작, 이전 맥락 활용 불가	대화 기록, 작업 상태, 사용자 선호

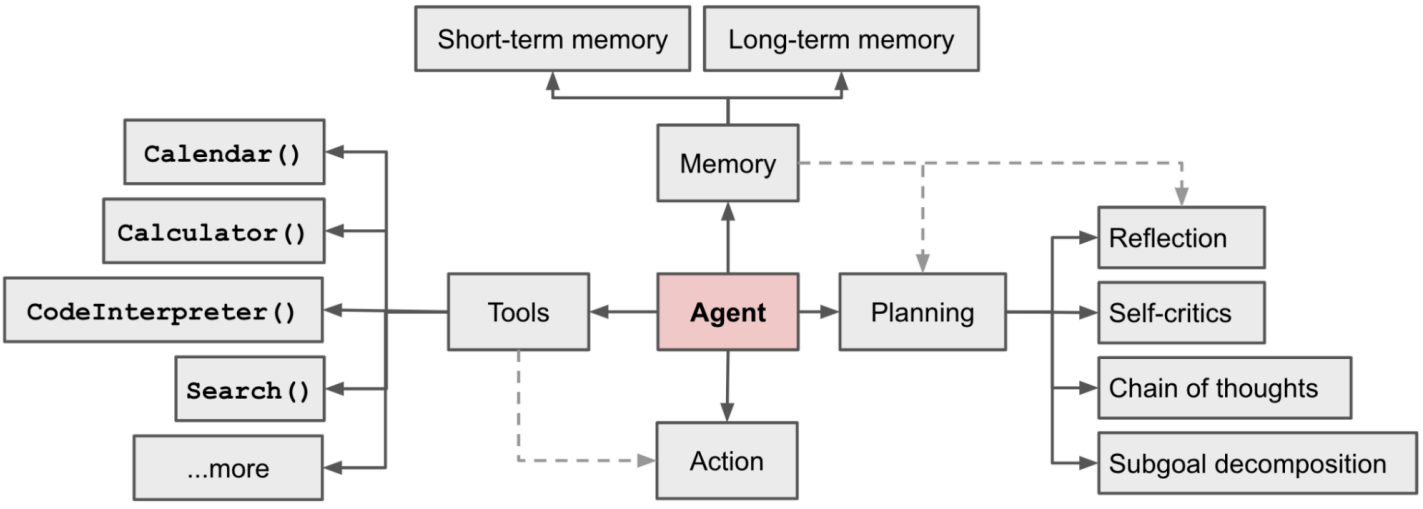

동일한 모델과 도구를 사용해도 **Instructions가 다르면 완전히 다른 Agent**가 됩니다 (Ch4의 SKILL.md가 바로 이 역할). Memory 없이는 어제 분석한 결과를 오늘 활용할 수 없습니다.

직접 실험해 볼까요? (5분)

`code/ch1-llm-basics/llm_experiment.ipynb` 의 **실험 3**을 열어서, 같은 질문("메일함에 뭐가 왔어?")에 System Prompt를 3가지로 바꿔보세요. Instructions가 Agent의 행동을 얼마나 바꾸는지 체감합니다.

이 네 가지 중 **Model**은 API 키 하나로 바로 사용할 수 있고, **Instructions**는 Ch4(SKILL.md)에서, **Memory**는 Ch2(Checkpointer)와 Ch3(FilesystemBackend)에서 깊이 다룹니다. 여기서는 Agent의 가장 특징적인 요소이면서 실무에서 혼동이 많은 **Tools의 내부 동작**을 먼저 살펴봅니다.

2.3.1 Tools는 내부적으로 어떻게 동작하는가?

핵심은 단순합니다. **LLM이 "툴 호출"이라는 특별한 형식의 텍스트(구조화된 토큰)를 생성**하고, 런타임이 그 형식을 읽어 실제 함수를 실행합니다.

```
1) 개발자: Tool 스키마 제공 (이름, 설명, 인자 JSON 스키마)
2) LLM: 일반 답변 대신 tool_call(name, args) 생성
3) 런타임: args 검증 후 실제 함수/API 실행
4) 런타임: 실행 결과를 ToolMessage로 다시 LLM에 전달
5) LLM: 관찰 결과를 바탕으로 다음 행동 또는 최종 답변 생성
```

즉, Tool Use는 "모델이 직접 코드를 실행"하는 것이 아니라, **모델이 실행 지시를 구조화해서 내고 시스템이 대신 실행**하는 방식입니다.

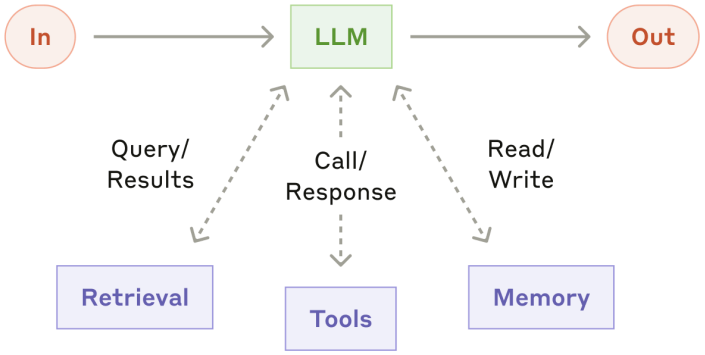

Anthropic "Building Effective Agents"
— Augmented LLM. LLM이 Retrieval(검색), Tools(도구 호출), Memory(기억)와 양방향으로 상호작용하는 기본 구조입니다.

> 직접 실험해 볼까요? (3분)
>
> `code/ch1-llm-basics/llm_experiment.ipynb` 의 **실험 4**를 열어서, `check_weather` Tool을 바인딩한 LLM에게 "서울 날씨 알려줘"(Tool 필요)와 "안녕하세요"(Tool 불필요)를 각각 보내보세요. `tool_calls` 필드가 언제 채워지는지 관찰합니다.

⏱ 09:35

2.4 Anthropic의 핵심 교훈: Agent는 마지막 수단

Anthropic의 "Building Effective Agents" (2024)에서 강조하는 핵심 원칙:

> 단순한 구성으로 해결되는 문제에 불필요한 복잡성을 더하지 마라. 가장 단순하고 신뢰할 수 있는 구현을 우선하라.
> — Anthropic (의역)

Anthropic이 수백 개의 Agent 프로덕션 사례를 분석한 결과를 기반으로, **워크플로우를 복잡도 순서로 단계화**할 수 있습니다. 단순한 작업을 무조건 Agent로 만드는 것은 비효율적입니다.

Anthropic은 "Building Effective Agents" (2024)에서 "Agentic Systems"를 **Workflows**와 **Agents** 두 범주로 명확히 구분합니다.

- **Workflows**: 실행 흐름이 **코드로 사전 정의**된 시스템
- **Agents**: LLM이 **자율적으로** 프로세스와 도구 사용을 지휘하는 시스템

Workflows (실행 흐름이 사전 정의됨)

[1] 단일 LLM 호출
입력 → LLM → 출력

입력: "아래 메일 3통을 요약해줘: [메일 본문]"
출력: "1. 서버 점검 안내 2. 워크숍 일정 3. 미팅 요청"

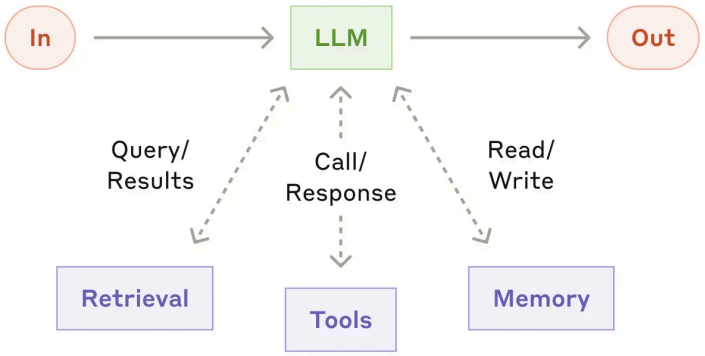

[2] 프롬프트 체이닝
입력 → LLM_1 → [Gate: 검증] → LLM_2 → LLM_3 → 출력
LLM_1: "메일 5통을 긴급/일반/마케팅으로 분류해"
Gate: 분류 결과가 유효한가? (Pass → 계속 / Fail → 조기 종료)
LLM_2: "긴급 메일의 상세 내용을 가져와"
LLM_3: "결과를 종합하여 보고서 작성"

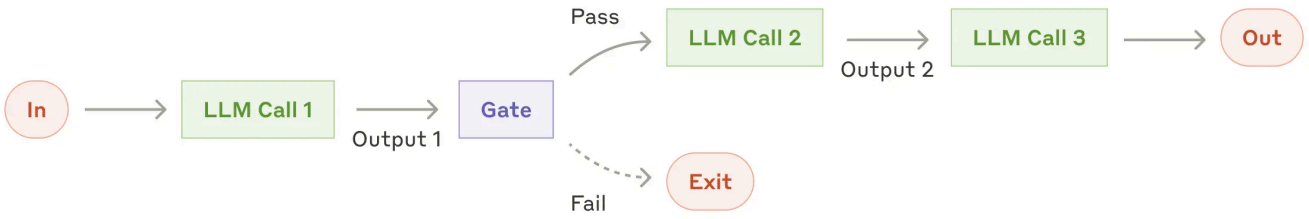

[3] 라우팅
입력 → 분류 LLM(Router) → 전문 LLM 선택 → 출력 (하나만 실행)
입력: "새 메일 도착"
Router 분류 결과에 따라:
→ "긴급 문의" → 즉시 답장 생성 LLM
→ "환불 요청" → 환불 절차 안내 LLM

→ "일반 질문" → FAQ 매칭 LLM (경량 모델로 처리)

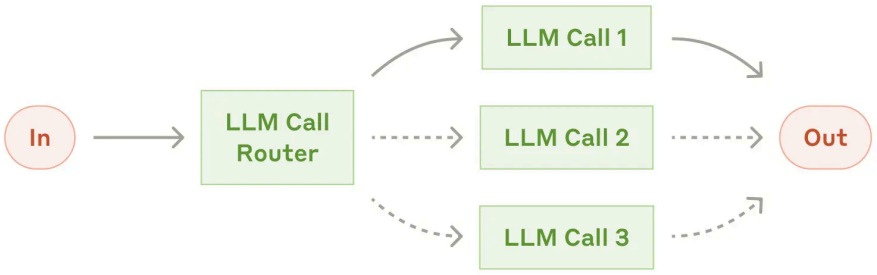

[4] 병렬화
입력 ─┬→ LLM_A ─┐
├→ LLM_B ─┼→ 통합 → 출력
└→ LLM_C ─┘
입력: "오늘 업무 현황" → A: 메일 분석 / B: 캘린더 확인 / C: 슬랙 조회 → 통합 보고

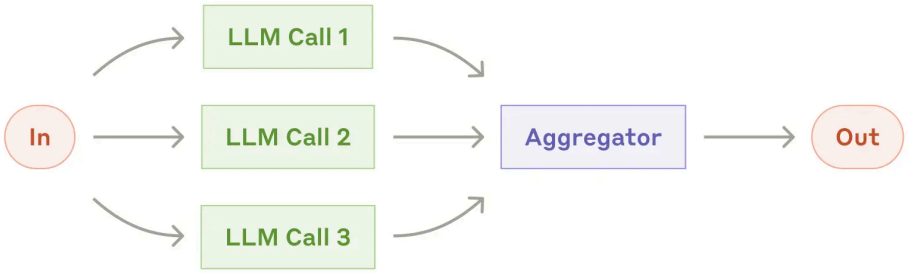

[5] 오케스트레이터-워커
중앙 LLM이 작업을 동적으로 분해하고 워커 LLM에 위임
입력: "메일 100통 분석해줘" → 오케스트레이터: "10통씩 나눠서 처리" → 워커들이 병렬 분석

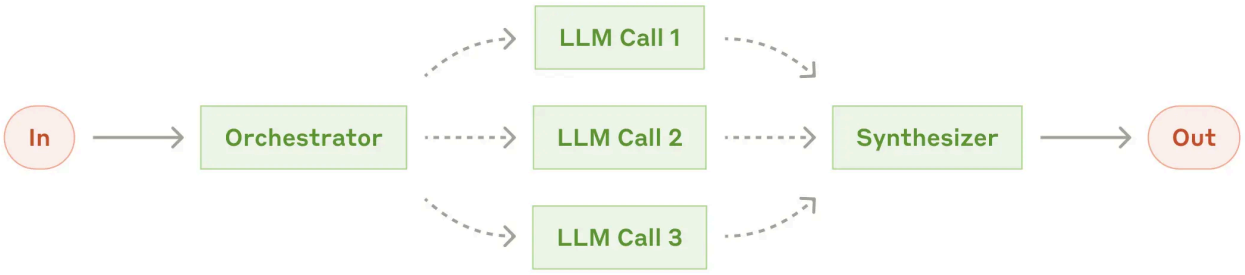

> **참고**: Anthropic 원문에는 [6] 평가자-최적화자(Evaluator-optimizer) 패턴도 있습니다 — 생성 LLM과 평가 LLM이 반복 피드백 루프를 도는 구조입니다. 본 교재에서는 [1]~[5]에 집중합니다.

Agents (LLM이 자율적으로 지휘)

Workflows는 실행 흐름의 **구조**가 코드로 사전 정의되어 있지만(분해→위임→종합), Agents는 LLM이 **스스로 계획을 세우고, 어떤 도구를 쓸지, 몇 번 반복할지, 언제 멈출지를 자율 결정**합니다.

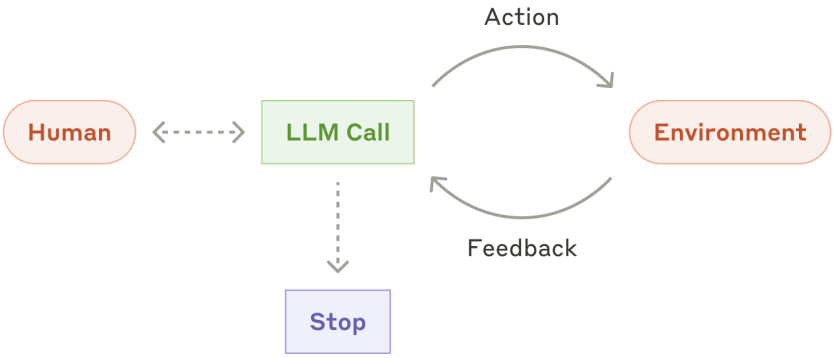

Anthropic "Building Effective Agents" — Autonomous Agent.
Human과 상호작용하며, LLM이 Environment에 Action을 보내고 Feedback을 받는 루프를 자율 반복합니다.

"오늘 업무 전체를 알아서 처리해줘" 같은 열린 작업이 Agent의 영역입니다. Ch5(A2A)에서 Check Agent와 Notify Agent를 연결하는 실습이 이 패턴의 축소판입니다.

오늘의 실습은 Agent에 집중합니다. 단, Workflows로 충분한 문제에 Agent를 강요하지 않아야 합니다. Agent는 자율 판단을 위해 매 호출마다 수천 토큰의 시스템 프롬프트와 대화 기록을 재전송하므로, 동일 작업을 Workflow로 처리할 때보다 **토큰 비용이 수 배** 높아집니다. (Ch3에서 실제 수치를 확인합니다.)

상황	권장 방식
정해진 순서의 작업	프롬프트 체이닝 [2]
종류에 따라 다른 처리	라우팅 [3]
독립적인 여러 작업	병렬화 [4]
작업 분해가 필요하지만 흐름은 예측 가능	오케스트레이터-워커 [5]
예측 불가한 복잡한 작업, 자율 판단 필요	**Agent**

? 빠른 판단 연습 (2분)

아래 상황에서 Workflow([1]~[5])와 Agent 중 어느 패턴이 가장 적합한지 고르세요.

상황	답
수신된 계약서를 번역한 뒤 법률팀 양식에 맞춰 요약	???
접수 메일이 "기술 문의"인지 "주문 문의"인지에 따라 다른 LLM으로 처리	???
"오늘 팀 전체 메일을 확인하고, 중요한 건 알림, 일반 건은 정리, 답장이 필요한 건 초안 작성해줘"	???

먼저 직접 답을 적어본 뒤, 아래 정답을 확인하세요.

정답:

- 계약서 번역→요약 → **[2] 프롬프트 체이닝** (Workflow) — 번역→요약의 순서가 사전에 고정
- 기술 문의 vs 주문 문의 → **[3] 라우팅** (Workflow) — 입력 종류에 따른 분기
- 팀 메일 전체 처리 → **Agent** — 사전에 정해지지 않은 동적 판단과 여러 도구 사용, 자율 계획 필요

⏱ 09:40

3. LLM → Agent → Agent Harness 변화

3.1 왜 Agent만으로는 부족한가?

ReAct Agent는 강력하지만, **실제 프로덕션 환경**에서는 새로운 문제가 발생합니다.

```
[단순 Agent의 한계]

1. 컨텍스트 윈도우 소진
   - 메일 100통 분석하다 보면 컨텍스트가 가득 참
   - 이전 분석 결과가 날아감

2. 장기 실행 불가
   - "매일 아침 9시에 메일 체크" 같은 반복 작업
   - 하나의 LLM 호출로는 불가능

3. 상태 관리의 복잡성
   - 작업 중 실패 시 어디서부터 재시작?
   - 여러 단계에 걸친 작업의 진행 상황 추적

4. 확장성
   - 새로운 기능(Skill) 추가가 어려움
   - Agent 간 협업 방법 부재
```

이 네 가지 문제는 **하나의 ReAct 루프 안에서는 해결할 수 없습니다**. 각각 다른 계층의 해법이 필요합니다.

문제	해결 계층	해법
컨텍스트 소진	**Harness**	Filesystem Backend로 컨텍스트 밖에 저장
장기 실행 불가	**Runtime + Harness**	Checkpointer(상태 저장) + 폴링/스케줄링
상태 관리 복잡성	**Harness**	Planning 미들웨어(TODO 추적) + 파일 기반 진행 관리
확장성	**Harness**	Skills 모듈화 + Subagent 위임 + A2A 통신

이를 체계적으로 해결하기 위해, Agent 기술은 3단계 계층으로 진화해왔습니다.

3.2 Framework → Runtime → Harness 3계층

같은 예제를 기준으로 보면 경계는 다음과 같습니다.

- Framework: `llm = ChatOpenAI(...)`, `@tool`, `llm.bind_tools(...)`
- Runtime: `StateGraph(...)`, `add_node`, `add_edge`, `add_conditional_edges`, `checkpointer`
- Harness: 파일시스템/Planning/Skills/Subagent를 조합해 장기 실행을 운영하는 계층

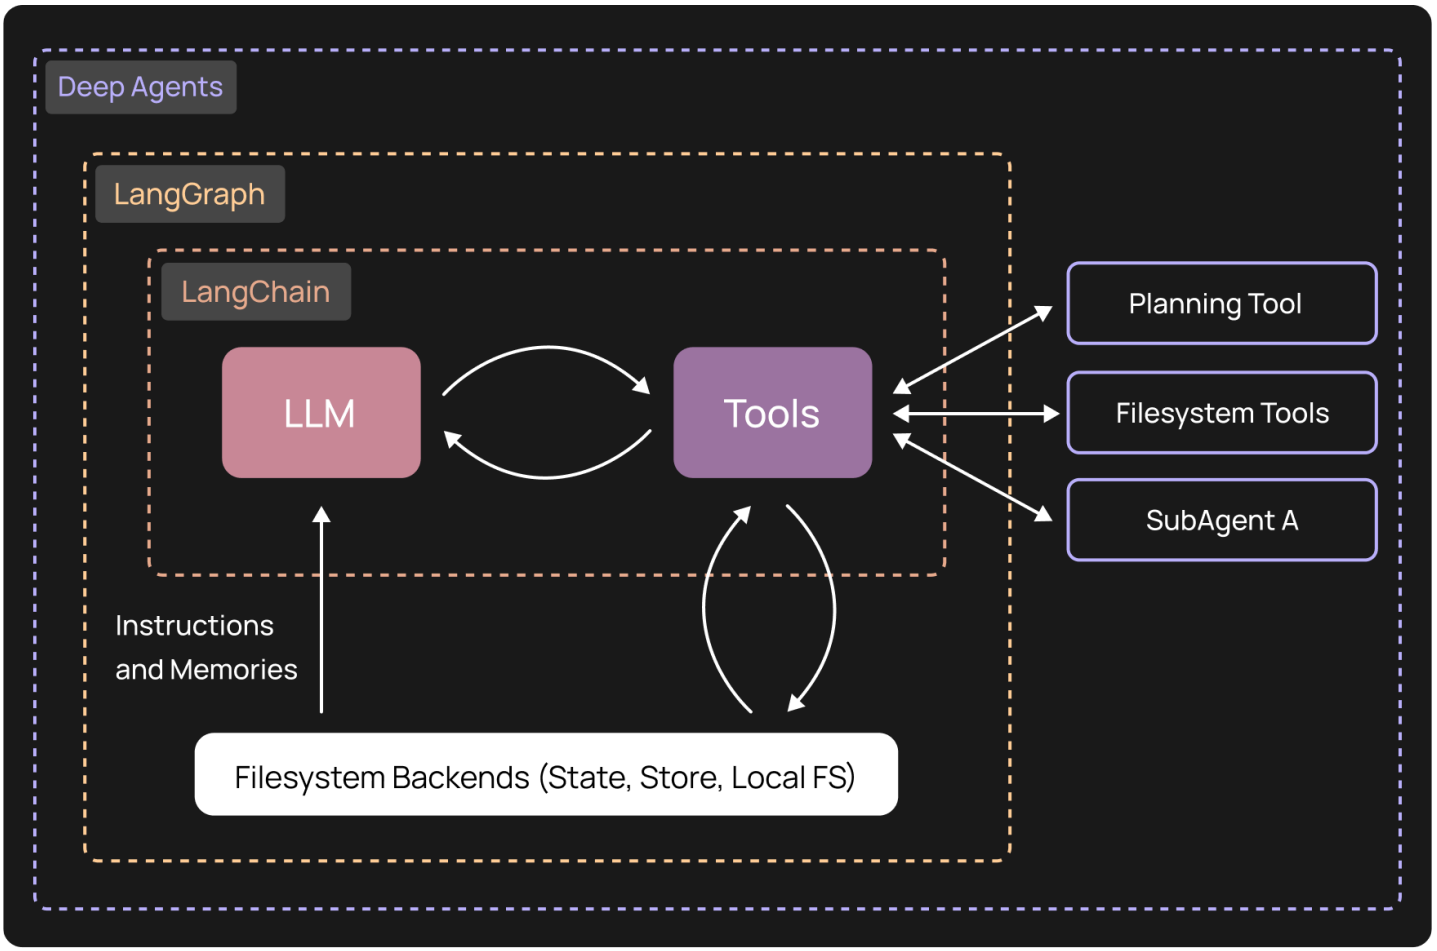

위 그림을 안쪽(Framework)부터 바깥쪽(Harness)으로 설명하면 다음과 같습니다.

- **Framework (가장 안쪽)** — LLM 통합, Tool 바인딩, 프롬프트 관리. `ChatOpenAI(...)`, `@tool`, `bind_tools()` 가 이 계층입니다.
- **Runtime (중간)** — 상태 관리, 조건부 분기, 순환, 체크포인트. `StateGraph`, `add_conditional_edges`, `checkpointer` 가 여기에 해당합니다.
- **Harness (가장 바깥)** — Long-Running 실행, Skills 관리, 파일시스템 메모리, Planning 자동화, 하위 Agent 위임, 외부 상태 저장. `FilesystemBackend`, `skills=[...]` 로 접근하는 모든 것이 이 계층입니다.

계층	대표 기술	해결하는 문제	비유
Framework	LangChain, LlamaIndex	LLM과 Tool 연결, 기본 체이닝	도구 상자 (망치, 드라이버)
Runtime	LangGraph, AutoGen	상태 관리, 순환, 조건부 라우팅	작업 공정표 (순서, 조건)
Harness	DeepAgents, Claude Code	Long-Running, Planning, Skills, 파일시스템	작업 현장 관리자

> 주의: 이 3계층은 **LangChain 생태계에서 자주 쓰는 설명 프레임**이며, 업계 전체의 단일 표준 taxonomy는 아닙니다. 다른 프레임워크는 runtime/framework 경계를 다르게 정의할 수 있습니다.

왜 이 기술 스택인가? 본 과정에서 LangChain → LangGraph → DeepAgents를 선택한 이유는 3계층이 명확히 분리되어 있어 각 계층의 역할을 개별적으로 학습하기에 적합하기 때문입니다. CrewAI나 AutoGen 같은 대안도 있지만, 이들은 여러 계층이 하나로 묶여 있어 "어디까지가 Framework이고 어디서부터 Harness인지" 구분하기 어렵습니다.

3.3 각 계층의 역할

Framework (LangChain)

```
# Framework = LLM과 Tool을 연결하는 기본 인프라
from langchain_openai import ChatOpenAI
from langchain_core.tools import tool

llm = ChatOpenAI(model="gpt-4o")

@tool
def check_inbox():
    """메일함의 미읽은 메일을 확인합니다."""
    ...
```

```
# LLM에 Tool을 바인딩
llm_with_tools = llm.bind_tools([check_inbox])
```

Runtime (LangGraph)

```
# Runtime = 상태 관리 + 실행 흐름 제어
from langgraph.graph import StateGraph

# 노드(작업)와 엣지(흐름)로 Agent의 실행 경로를 정의
graph = StateGraph(AgentState)
graph.add_node("check", check_node)
graph.add_node("analyze", analyze_node)
graph.add_conditional_edges("analyze", should_continue)
# → 상태에 따라 순환, 분기, 중단이 가능
```

Harness (DeepAgents)

```
# Harness = Agent 실행 전체를 관리하는 인프라
# - 파일시스템에 상태 저장 → 컨텍스트 윈도우 한계 극복
# - Planning 도구로 작업 추적 → Long-Running 가능
# - Skills로 절차적 지식 모듈화 → 확장성
# - 하위 Agent 위임 → 복잡한 작업 분할
from deepagents.backends import FilesystemBackend

agent = create_deep_agent(
    model="openai:google/gemini-3-flash-preview",
    backend=FilesystemBackend(root_dir="./workspace", virtual_mode=True),
    skills=["./skills/mail_skill"],
)
```

위 코드는 Ch3와 동일한 **실행 가능한 문법**으로 맞췄습니다. 강의 전체에서 `backend=...`, `skills=[...]` 형태를 표준으로 사용합니다.

체크포인트 2 (1분)

아래 코드 조각이 3계층 중 어디에 해당하는지 연결해보세요.

코드	계층은?
`llm.bind_tools([check_inbox])`	???
`graph.add_conditional_edges(...)`	???
`backend=FilesystemBackend(...)`	???

먼저 직접 답을 적어본 뒤, 아래 정답을 확인하세요.

정답:

- `llm.bind_tools(...)` → **Framework** — LLM에 Tool을 연결
- `graph.add_conditional_edges(...)` → **Runtime** — 조건부 분기를 정의
- `backend=FilesystemBackend(...)` → **Harness** — 파일시스템으로 컨텍스트 밖 상태 관리

3.3.1 Framework 계층의 다른 선택지 — Pydantic AI

본 과정에서는 LangChain을 Framework로 사용하지만, 2025년 하반기부터 **Pydantic AI** 가 빠르게 부상하고 있어 알아둘 필요가 있습니다.

Pydantic AI는 Python 검증 라이브러리 Pydantic을 만든 팀이 개발한 경량 Agent 프레임워크입니다 (2025년 9월 v1.0 출시, 2026년 3월 GitHub Stars 15k+). 핵심 철학은 **"FastAPI가 웹 개발에 가져온 경험을 Agent 개발에도"** — Python 타입 힌트와 Pydantic 검증을 전면 활용하여, 입력·출력·Tool 인자까지 모두 타입 안전하게 정의합니다.

	LangChain	Pydantic AI
설계 철학	파이프라인·체인 중심, 풍부한 생태계	타입·함수 중심, 경량 도구킷
비유	Django (배터리 포함)	FastAPI (집중·간결)
3계층 위치	Framework (+Runtime은 LangGraph)	Framework 전용 (Runtime/Harness는 외부 조합)

```python
# Pydantic AI 예시 — 같은 Tool 정의가 타입 안전하게 작성됩니다
from pydantic_ai import Agent

agent = Agent(
    "openai:gpt-4o",
    system_prompt="당신은 메일 관리 비서입니다.",
)

@agent.tool_plain
def check_inbox() -> str:
    """메일함의 미읽은 메일을 확인합니다."""
    return "미읽은 메일 3통"
```

Pydantic AI는 Framework 계층에 집중하므로, LangGraph 같은 Runtime이나 DeepAgents 같은 Harness를 **별도로 조합**해야 합니다. 본 과정에서 LangChain을 선택한 이유는 3계층이 하나의 생태계(LangChain → LangGraph → DeepAgents)로 연결되어 학습 흐름이 자연스럽기 때문입니다. 실무에서는 프로젝트 성격에 따라 Pydantic AI를 선택하는 팀도 늘고 있으니, Framework 계층의 대안으로 기억해두세요.

3.4 왜 Harness가 필요한가?

Agent Harness는 AI Agent의 실행을 감싸는 **제어 평면(control plane)** 입니다. 모델을 교체하지 않고, 모델이 동작하는 **환경과 조건**을 설계합니다. Birgitta Bockeler는 martinfowler.com에서 이를 "AI 에이전트를 통제하기 위해 사용하는 도구와 관행(tooling and practices to keep AI agents in check)"이라고 정의합니다.

Harness가 없는 Agent는 다음과 같은 문제에 부딪힙니다:

```
[Harness 없이 Agent를 운영하면?]

1. 컨텍스트 소진  — 메일 100통 분석하다 윈도우가 가득 차서 이전 결과 소실
2. 무한 재시도    — 같은 에러를 반복하며 비용만 소모 (doom loop)
3. 상태 소실      — 작업 중 실패 시 처음부터 재시작
4. 장기 실행 불가  — "매일 아침 메일 체크" 같은 반복 작업을 하나의 호출로 처리 불가
5. 보안 취약      — 도구가 시스템 전체에 접근 가능 (디렉토리 traversal, 키 노출)
6. 관찰 불가      — 에이전트가 왜 그렇게 판단했는지 추적 불가
```

Harness가 해결하는 문제 영역:

영역	Harness의 해법	없으면?
컨텍스트 관리	자동 요약, 파일시스템으로 대형 출력 퇴피	매번 컨텍스트에 모든 데이터를 넣어야 함
에러 복구	루프 감지, 재시도 전략, 폴백 행동 정의	동일 실패를 무한 반복
상태 지속	파일시스템/체크포인트 기반 진행 추적	진행 상황을 추적할 방법 없음
계획 강제	TODO 리스트로 계획-실행-검증 루프 강제	모델이 검증 없이 근시안적 행동
Skills	절차적 지식을 SKILL.md로 모듈화	매번 프롬프트에 절차를 설명해야 함
Subagent	복잡한 작업을 하위 Agent에게 위임	하나의 Agent가 모든 것을 처리해야 함
보안	경로 검증, 도구 권한 제어, 샌드박스 실행	도구가 시스템 전체에 무제한 접근
비용 제어	예산 설정, 반복 횟수 제한	무한 루프로 비용 폭주

> LangChain이 DeepAgents(Harness)를 도입하여 같은 모델·Runtime으로 Terminal Bench 점수 52.8% → 66.5%, Top 30 밖 → Top 5로 올라갔습니다 (자세한 내용은 Ch3 참고). OpenAI도 Codex에 Harness를 적용하여 3명의 엔지니어가 5개월간 100만 줄 코드, 1,500 PR을 생성했습니다. **모델이 아니라 Harness가 차이를 만듭니다.**

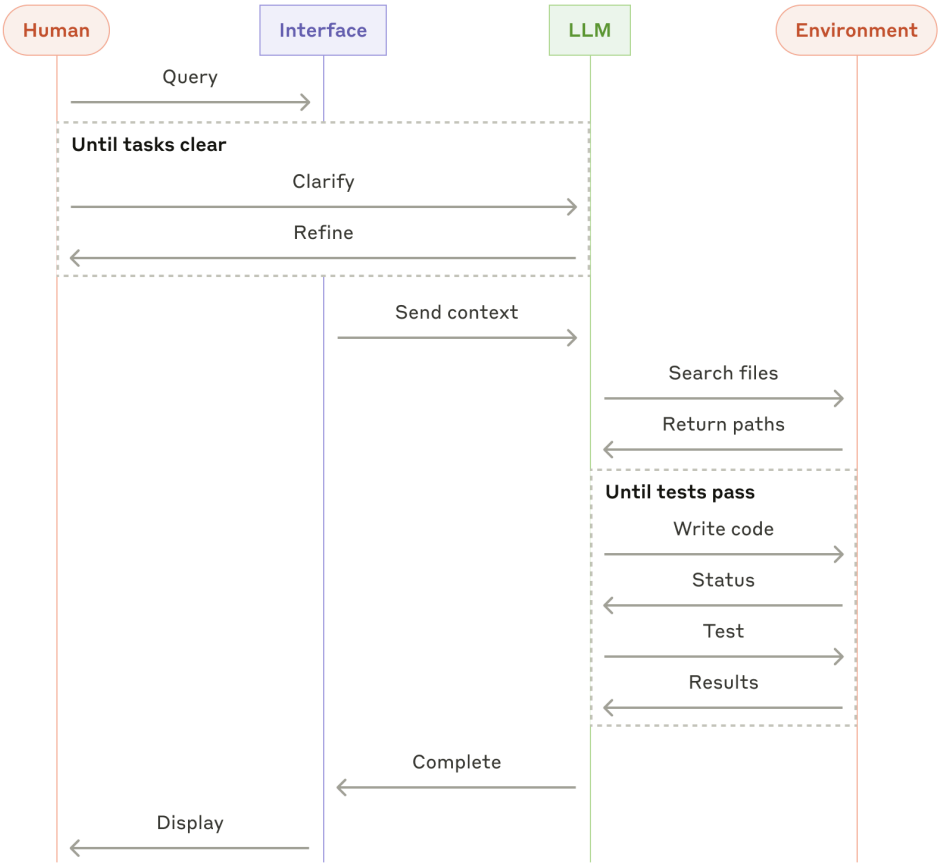

Anthropic "Building Effective Agents" — Coding Agent의 실행 흐름.
Human이 Query를 보내면 Interface가 LLM에 Context를 전달하고, LLM은 파일을 검색·코드를 작성·테스트를 반복한 뒤 결과를 반환합니다. 이 전체 과정을 관리하는 것이 Harness의 역할입니다.

⏱ 09:47

4. 오늘의 로드맵

오늘 하루 동안 아래 순서로 Agent의 3계층을 직접 체험합니다.

```
시간   Chapter                          체험하는 계층
────   ──────────────────────────────   ────────────
1.0h   Ch1. Kick-off & Agent 패러다임    (지금 여기!) 이론
       ──────────────────────────────
2.0h   Ch2. LangChain/LangGraph Agent    Framework + Runtime
       ├─ Step 1: 단일 Agent Loop         └─ LangChain 기초
       ├─ Step 2: Tool 호출 / 상태 관리   └─ LangGraph 기초
       ├─ Step 3: 상태·재시도·중단         └─ 체크포인터, HITL
       └─ Step 4: Long-Running Agent       └─ "직접 만들면 힘들다!"
       ──────────────────────────────
2.0h   Ch3. DeepAgents & Harness         Harness
       ├─ Step 1: Agent 초기화            └─ 기본 설정
       ├─ Step 2: Filesystem 활용         └─ 외부 메모리
       ├─ Step 3: Planning 도구           └─ 작업 추적
       └─ Step 4: 폴링 구성               └─ 반복 실행
       ──────────────────────────────
1.0h   Ch4. Skills & MCP 연계            Skills + MCP
       └─ 메일 체크 시나리오 구현
       ──────────────────────────────
1.0h   Ch5. A2A로 역할 분리              Agent 간 통신
       └─ Check Agent ↔ Notify Agent
       ──────────────────────────────
```

```
1.0h   Ch6. 통합 Demo & Wrap-up            전체 통합
       └─ End-to-End 메일 Agent
```

스토리라인:

- **오전:** LangChain/LangGraph로 Agent를 직접 만들며 "왜 힘든지" 체감 → DeepAgents로 "이렇게 쉬워진다" 체험
- **오후:** Skills/MCP로 메일 체크 기능 구현 → A2A로 Agent 간 협업 → 전체 통합

⏱ 09:48 – 마무리

핵심 요약

개념	핵심 포인트
LLM	다음 토큰 예측기. Stateless, Context Window, Hallucination, Knowledge Cutoff 4가지 한계
Agent	ReAct(Thought→Action→Observation) 루프로 LLM의 한계를 극복하는 시스템
Framework	LLM과 Tool을 연결하는 기본 인프라 (LangChain)
Runtime	상태 관리, 순환, 조건부 분기를 지원하는 실행 엔진 (LangGraph)
Harness	Agent 실행의 신뢰성·확장성을 관리하는 제어 평면 (DeepAgents)

실무 적용 팁:

- **프로토타이핑 시작점:** 새 프로젝트에서 Agent가 필요한지 판단하려면 위 복잡도 단계([1]~[5])를 먼저 체크하세요. 대부분의 업무는 [2] 프롬프트 체이닝이나 [3] 라우팅으로 충분합니다.
- **temperature 설정:** 정확한 분류/추출 작업에는 `temperature=0`, 창의적 생성에는 `0.7~1.0`이 실무 기본값입니다. Agent의 Tool 호출 판단에는 반드시 낮은 temperature를 사용하세요.

> **다음 Chapter:** LangChain과 LangGraph로 직접 Agent를 만들어보며, Framework와 Runtime의 역할을 체험합니다.

⏱ 09:50~10:00 쉬는 시간

참고 자료

- ReAct: Synergizing Reasoning and Acting in Language Models (2022)
- LangChain 공식 문서
- LangGraph 공식 문서
- DeepAgents GitHub
- Anthropic - Building Effective Agents
- Karpathy microGPT
- Karpathy 2025 LLM Year in Review
- SWE-Bench 리더보드 — 본문 벤치마크 수치 출처
- LangChain Deep Agents 블로그 — Terminal Bench 결과 수치 출처
- Are Emergent Abilities of Large Language Models a Mirage? (Schaeffer et al., 2023)
- A Survey on Hallucination in Large Language Models (Huang et al., 2023)
- Why Language Models Hallucinate (Kalai et al., OpenAI, 2025) — 훈련·평가 인센티브가 환각을 조장하는 메커니즘
- Hallucination is Inevitable (Xu et al., 2025) — 환각이 LLM의 본질적 한계임을 수학적 증명
- OpenAI - A Practical Guide to Building Agents — Agent 구성요소(Model+Instructions+Tools) 정의
- LLM 기반 자율 에이전트 | 릴 로그
- OpenAI - Harness Engineering: Leveraging Codex — Codex Harness 사례
- Martin Fowler - Harness Engineering — Harness 정의와 범주
- GeekNews - Codex 하네스 활용하기 — OpenAI App Server 아키텍처 한국어 해설
- 딥에이전트에 더 투자하다
- Karpathy on X — "80% Agent 코딩" (2026-01)
- OpenClaw AI — 오픈소스 자율 AI Agent
- Claude Cowork (Anthropic) — 범용 AI Agent
- Defeating Nondeterminism in LLM Inference (Thinking Machines Lab, 2025) — GPU 비결정성 분석
- OpenAI Cookbook — Reproducible Outputs with Seed

- Anthropic Glossary — Temperature — "Even with temperature set to 0, results will not be fully deterministic"
- Pydantic AI 공식 문서 — 경량 Agent 프레임워크
- Pydantic 공식 문서
- Google Agents Whitepaper (2024) — Model + Orchestration + Tools 3계층 정의