Chapter 3. DeepAgents와 Harness 실습

Chapter 3. DeepAgents & Harness 개념, 실습

> 학습 목표
>
> - ◯ Agent / Runtime / Harness 개념을 설명할 수 있다
> - ◯ DeepAgents의 핵심 미들웨어(Filesystem, Skills, SubAgent, Summarization)가 각각 어떤 보일러플레이트를 대체하는지 설명할 수 있다
> - ◯ create_deep_agent()로 Agent를 초기화하고 활용할 수 있다
> - ◯ Ch2에서 수동 구현한 것이 DeepAgents에서 어떻게 기본 제공되는지 비교할 수 있다
> - ◯ Context Engineering 개념과 Harness 적용이 성능에 미치는 영향(벤치마크 사례)을 설명할 수 있다

소요시간	학습방법
2.0h	이론/실습

⏱ 13:00 – 시작

이 챕터의 출발점

Ch2 Step 4에서 메일 100통을 분석하기 위해 파일시스템 Tool, TODO 관리, 배치 처리, 반복 제한 등 **~110줄의 보일러플레이트**를 직접 구현했습니다. 그리고 "이걸 매번 만들 수 없다!"는 결론에 도달했습니다.

이 챕터에서는 그 보일러플레이트를 **DeepAgents**가 어떻게 1줄로 대체하는지 체험합니다. 먼저 이론(Harness 개념)을 다진 뒤, 4개 Step에서 직접 코드를 실행합니다.

중요: Harness는 "항상 써야 하는 정답"이 아닙니다. 작업이 짧고 흐름이 단순하면 Ch2 방식으로 직접 구현해도 충분합니다. 이 챕터의 초점은 **롱러닝·다단계 작업에서 반복되는 공통 제어를 Harness로 표준화하는 방법**입니다.

⏱ 13:03

이론: Agent Harness란? (30분)

패러다임 전환: 프롬프트 엔지니어링 → 컨텍스트 엔지니어링

2025년 중반, AI 업계에서 "프롬프트 엔지니어링"을 넘어서는 새로운 사고방식이 급부상했습니다: **Context Engineering(컨텍스트 엔지니어링)**.

이 용어를 대중화한 건 Shopify CEO Tobi Lütke의 2025년 6월 트윗이었습니다.

> "I really like the term 'context engineering' over prompt engineering. It describes the core skill better: **the art of providing all the context for the task to be plausibly solvable by the LLM.**"
> — Tobi Lütke, 2025-06-19

이후 Andrej Karpathy(전 OpenAI 연구원), Anthropic, LangChain이 잇달아 같은 개념을 강조하며 업계 공통 언어가 되었습니다.

LangChain의 정의:

> "Context engineering is the art and science of filling the context window with just the right information at each step of an agent's trajectory."
> — Context Engineering for Agents (2025-07-02)

Anthropic의 정의:

> Context engineering은 프롬프트 엔지니어링의 자연스러운 진화이며, 프롬프트뿐 아니라 **추론 시점에 LLM에 도달하는 모든 정보**를 설계하는 것입니다.
> — Effective context engineering for AI agents (2025-09-29)

> 용어 주의: Context Engineering은 현재 학술 표준 용어라기보다 업계 실무에서 확산된 표현입니다. 본 교재에서는 context management/context curation 계열 실무를 묶어 설명하는 편의 용어로 사용합니다.

핵심 전략 4가지 (LangChain 정리 기준):

전략	설명	예시
Write	중요 정보를 컨텍스트 밖에 저장	파일에 중간 결과 기록
Select	필요한 정보만 컨텍스트로 불러옴	관련 파일만 `read_file`
Compress	불필요한 토큰 제거	대화 요약(Summarization)
Isolate	하위 작업별로 컨텍스트 분리	Subagent에게 독립 태스크 위임

구분	프롬프트 엔지니어링 (2023)	컨텍스트 엔지니어링 (2025+)
초점	좋은 지시문 작성	컨텍스트 창 전체를 설계
관심사	이번 호출의 품질	세션 간, 호출 간 흐름
도구	System Prompt	파일시스템, 메모리, TODO, Skills
비유	좋은 질문 하기	좋은 업무 환경 만들기

이 원칙을 시스템으로 구현한 것이 **Agent Harness**이며, DeepAgents는 그 대표적 구현체입니다. 각 전략이 DeepAgents의 어떤 미들웨어에 대응하는지는 아래에서 살펴봅니다.

컨텍스트 창에 들어오는 것들:

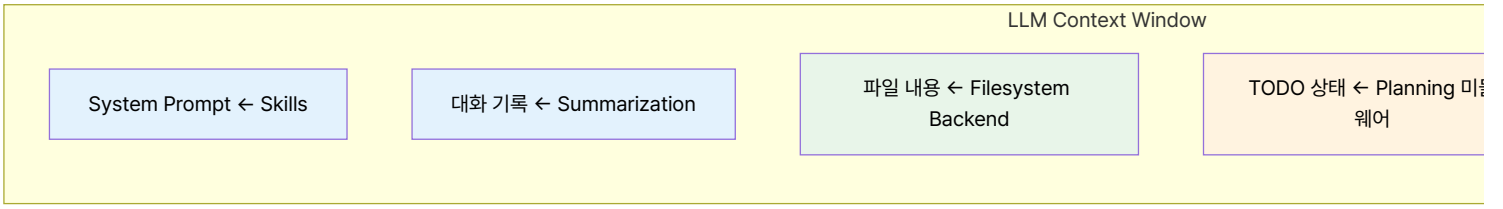

Harness의 역할: 이 컨텍스트 창을 올바르게 채우고 관리하는 인프라.

Harness = Agent를 감싸는 관리 인프라

Ch2에서 우리는 LangChain/LangGraph로 Agent를 구현하면서 **반복되는 보일러플레이트 코드**를 경험했습니다.

Ch2에서 직접 만든 것	코드량	매 프로젝트마다?
파일시스템 Tool (save/read)	~30줄	반복
TODO 관리 Tool	~30줄	반복
배치 처리 로직	~20줄	매번 다르게
컨텍스트 관리	~20줄	반복

Agent Harness는 이런 공통 기능을 미리 제공하는 관리 인프라입니다.

DeepAgents 소개

DeepAgents는 LangChain이 만든 오픈소스 Agent Harness 프레임워크입니다.

- LangGraph 위에 구축 (같은 Runtime 사용)
- Claude Code에서 영감 받은 설계
- MIT 라이선스 오픈소스

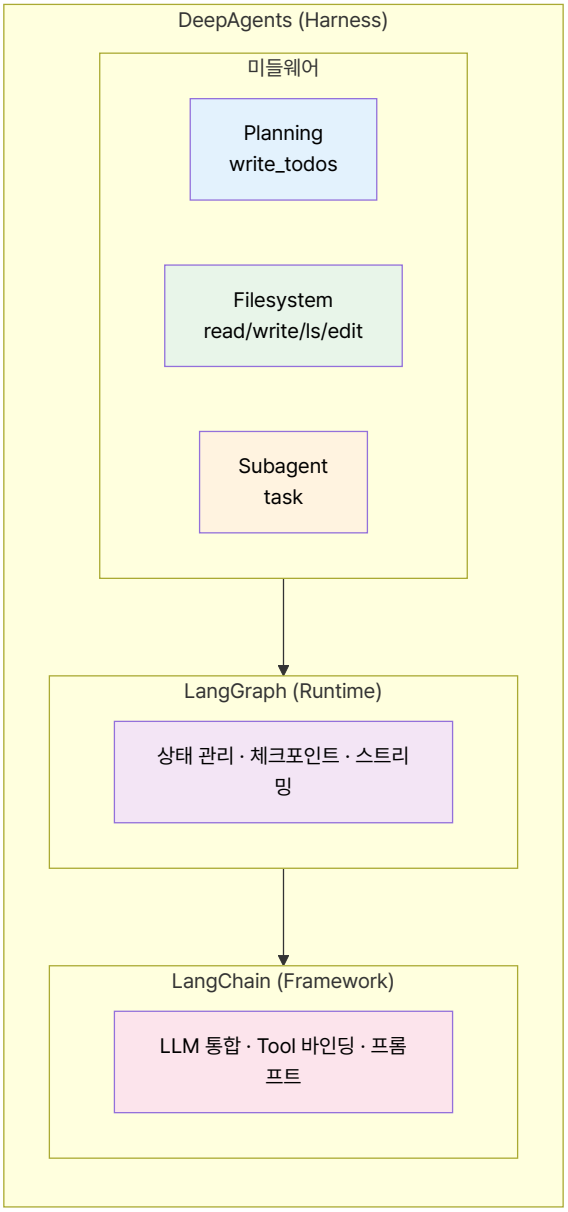

실증 데이터: Harness가 실제로 얼마나 효과적인가?

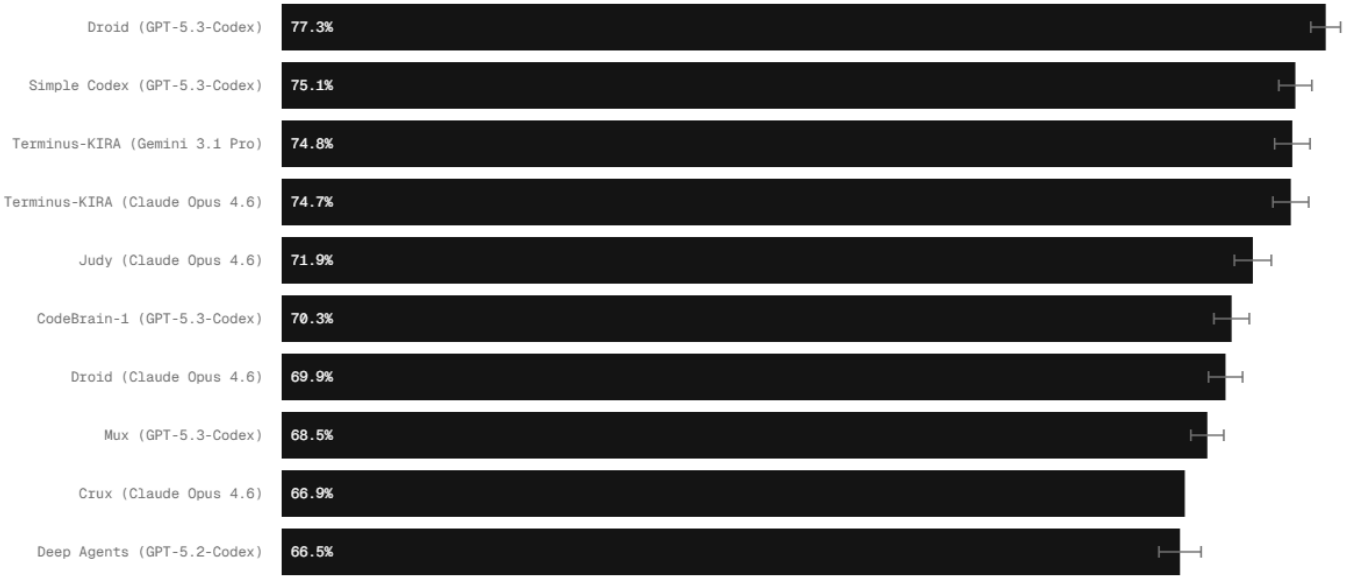

Terminal Bench 2.0 리더보드 (2026-02 기준, tbench.ai). Deep Agents는 Harness 적용으로 상위권에 진입했습니다.

Terminal Bench는 laude-institute가 만든 벤치마크로, AI 에이전트가 터미널 환경에서 머신러닝·디버깅·시스템 관리 등 **89개 실제 작업**을 자율 수행하는 능력을 평가합니다. SWE-bench가 코드 수정 능력을 측정한다면, Terminal Bench는 터미널 환경 전체를 조작하는 능력을 측정합니다. (Terminal Bench 공식)

LangChain 팀은 2026년 2월 블로그에서 **같은 모델(GPT-5.2-Codex), 같은 Runtime을 사용하되 Harness 구성만 개선했을 때** 성능이 어떻게 달라지는지를 공개했습니다.

```
[기준] DeepAgents 기본 설정:
  Terminal Bench 점수: 52.8%
  랭킹: Top 30 밖

[개선] Harness 미들웨어 추가·조정 후:
  Terminal Bench 점수: 66.5%  (+13.7%p)
  랭킹: Top 5

주요 개선 미들웨어:
  ✓ PreCompletionChecklistMiddleware → 완료 전 체크리스트 점검
  ✓ LocalContextMiddleware           → 관련 파일 맥락 자동 주입
  ✓ LoopDetectionMiddleware          → 반복 패턴 감지·탈출
```

출처: LangChain - Improving Deep Agents with harness engineering (2026-02-17)

> 이 수치는 LangChain 팀이 자체 블로그에서 공개한 결과(self-reported)입니다. 독립적인 제3자 재현은 아직 확인되지 않았으므로, "성능 보장 수치"가 아니라 **"harness 설계가 성능에 미치는 영향을 보여주는 사례"** 로 참고합니다.

핵심: 모델의 지능은 같아도, **어떤 컨텍스트를 제공하느냐**가 성능을 결정합니다.

점수 상승의 의미를 작업 단위로 바꾸면 더 직관적입니다. Terminal Bench가 89개 작업이라면, 52.8%는 약 47개, 66.5%는 약 59개를 성공한다는 뜻입니다. 즉 **동일 모델에서 약 12개 작업을 추가 성공**하게 되어, 실패 재시도·수동 개입·운영 시간이 줄어듭니다.

Ch2 수동 구현 vs DeepAgents 비교

기능	Ch2 (직접 구현)	DeepAgents (기본 제공)
파일 읽기/쓰기	`save_to_file`, `read_from_file` 직접 구현	`read_file`, `write_file`, `edit_file` 내장
파일 목록	미구현	`ls`, `glob`, `grep` 내장
작업 계획	`write_todos`, `read_todos` 직접 구현	`write_todos` 미들웨어로 자동 제공
하위 작업 위임	미구현	`task` Tool로 Subagent 자동 위임
컨텍스트 관리	수동 (MAX_ITERATIONS)	SummarizationMiddleware 자동
그래프 구성	StateGraph + Node + Edge (~30줄)	`create_deep_agent()` (1줄)

`create_deep_agent()` 미들웨어 스택

`create_deep_agent()` 를 호출하면 아래 미들웨어가 구성됩니다. **항상 포함**되는 4개와, 파라미터를 전달할 때만 활성화되는 **조건부** 미들웨어가 있습니다.

항상 포함 (기본 스택)

미들웨어	제공하는 Tool / 기능	역할
TodoListMiddleware	`write_todos`	작업 계획 수립 및 진행 추적
FilesystemMiddleware	`ls`, `read_file`, `write_file`, `edit_file`, `glob`, `grep`, `execute`	파일시스템 기반 외부 메모리 + 셸 실행
SubAgentMiddleware	`task`	복잡한 작업을 하위 Agent에게 위임
SummarizationMiddleware	자동 요약	대화가 길어질 때 컨텍스트를 압축

조건부 포함 (파라미터 전달 시)

미들웨어	활성화 조건	역할
MemoryMiddleware	`memory=["~/.deepagents/AGENTS.md"]`	AGENTS.md 등 프로젝트 메모리를 시스템 프롬프트에 주입
SkillsMiddleware	`skills=["/skills/user/"]`	SKILL.md 파일을 검색하여 절차적 지식을 주입 (Ch4에서 상세)
HumanInTheLoopMiddleware	`interrupt_on={"send_reply": True}`	지정 Tool 호출 전 사용자 승인 대기

> **패키지 출처**: `TodoListMiddleware`, `HumanInTheLoopMiddleware`, `SummarizationMiddleware` 는 `langchain.agents.middleware` 에서, `FilesystemMiddleware` 와 `SubAgentMiddleware` 는 `deepagents.middleware` 에서 제공됩니다. `create_deep_agent()` 가 내부적으로 LangChain의 `create_agent()` 를 호출하면서 양쪽 미들웨어를 조합합니다 (소스: `graph.py` L267-320).

사용자 정의 미들웨어를 `middleware=[]` 파라미터로 추가할 수 있습니다. 기본 스택 뒤에 append되므로, 기본 미들웨어를 제거하려면 `create_deep_agent()` 대신 `langchain.agents.create_agent()` 로 직접 구성해야 합니다.

```
# 커스텀 미들웨어 추가 (기본 스택 + 내 미들웨어)
agent = create_deep_agent(
    model="anthropic:claude-sonnet-4-20250514",
    middleware=[WeatherMiddleware()]  # 기본 스택 뒤에 추가됨
)

# 기본 미들웨어 없이 직접 구성 (create_agent 사용)
from langchain.agents import create_agent
agent = create_agent(
    model="anthropic:claude-sonnet-4-20250514",
    middleware=[TodoListMiddleware(), WeatherMiddleware()]  # 원하는 것만
)
```

> **Tool과 미들웨어의 차이**: 미들웨어는 LLM 호출 전후에 컨텍스트를 가공하는 **훅**(Hook)이고, Tool은 Agent가 호출하는 **함수**입니다. 웹 검색(Tavily)이나 MCP 연결은 미들웨어가 아닌 Tool로 `tools=` 파라미터에 전달합니다 (Ch4에서 실습).

Harness의 토큰 비용과 트레이드오프

미들웨어 스택은 **매 LLM 호출마다** 시스템 프롬프트에 지침을 주입합니다. 이것이 Harness의 비용입니다.

호출당 고정 오버헤드 (소스코드 기준)

구성 요소	주입 내용	추정 토큰
Base prompt	핵심 행동 지침, 객관성, 코드 관례	~1,300
SubAgentMiddleware	task 도구 설명, 위임 패턴, 병렬화 규칙	~460
TodoListMiddleware	Planning 절차, TODO 형식 규칙	~200
FilesystemMiddleware	파일·셸 도구 사용법, 경로 규칙	~210
Tool descriptions	내장 7개 도구의 상세 설명 (read_file이 ~330으로 가장 큼)	~935
Tool schemas	9개 내장 + 커스텀 도구의 파라미터 정의	~395
합계		**~3,500**

Ch2 수동 구현에서는 시스템 프롬프트가 2~3줄(~100 토큰)이었습니다. DeepAgents는 매 호출마다 **~3,500 토큰이 고정 추가**되고, 여기에 **대화 기록이 호출마다 누적**됩니다.

실제 비용 계산 예시: 메일 요약 작업에서 Agent가 LLM을 5회 호출한다고 가정합니다. 고정 오버헤드만 계산한 최소 비용입니다 (대화 기록 누적 제외).

모델	입력 단가 (/1M토큰)	고정 오버헤드 (3.5K × 5회)	추가 비용
Claude Sonnet 4.6	$3.00	17.5K 토큰	**$0.053**
GPT-5.4	$2.50	17.5K 토큰	**$0.044**
Gemini 3 Flash Preview	$0.50	17.5K 토큰	**$0.009**

> 가격은 2026-03 기준 OpenRouter API 조회 값입니다. 최신 가격은 각 제공사 또는 OpenRouter에서 확인하세요.

프롬프트 캐싱으로 비용 절감: DeepAgents는 `AnthropicPromptCachingMiddleware` 를 기본 포함합니다. 이 미들웨어는 시스템 프롬프트 + Tool 정의를 자동으로 캐싱하여, 동일 세션 내 후속 호출에서 **캐시 히트** 시 입력 토큰 비용을 대폭 절감합니다.

제공사	캐시 히트 할인율	캐시 쓰기 비용
Anthropic	**입력 대비 90% 할인** ($0.30/MTok)	1.25배 ($3.75/MTok, 5분 TTL)
OpenAI	입력 대비 50% 할인 ($1.25/MTok)	자동
Google	입력 대비 90% 할인 ($0.03/MTok)	별도 저장 비용

Claude Sonnet 4.6 기준으로 5회 호출 시:

```
캐싱 없이:  3,500 × 5 × $3.00/MTok  = $0.053
캐싱 적용:  3,500 × $3.75/MTok (첫 호출 write)
          + 3,500 × 4 × $0.30/MTok (후속 read)
          = $0.013 + $0.004 = $0.017

→ 약 68% 절감, 레이턴시도 최대 85% 단축
```

> **핵심: 코드를 토큰으로 교환한 것이 아니라, 성능을 토큰으로 구매한 것입니다.** Ch2 수동 구현에서 DeepAgents로 전환하면 코드가 간단해지는 것만이 아닙니다. 미들웨어가 주입하는 ~3,500 토큰은 "Planning을 이렇게 하라", "파일에 이렇게 저장하라", "하위 작업은 이렇게 위임하라"라는 **구조화된 지침**입니다. 이 지침이 LLM의 행동 품질을 올리기 때문에, Terminal Bench에서 동일 모델(GPT-5.2-Codex)로 52.8% → 66.5%의 성능 향상이 나온 것입니다. 호출당 $0.01 미만의 추가 비용으로 **+13.7%p의 성능 향상**을 얻는 것이 Harness 엔지니어링의 핵심 트레이드오프입니다.

실행 결과 예시 — "중요 메일을 확인하고 요약을 파일에 저장해줘"라는 요청을 처리한 결과입니다.

```
$ uv run python3 ch3-deepagents/step1_init_agent.py

--- Agent 최종 응답 ---
중요 메일 3통을 확인하고 내용을 요약하여 mail_summary.md에 저장했습니다.

--- Agent State (messages 제외) ---
  messages: [13개 메시지]
  files: {
      "/mail_summary.md": {
          "content": ["# 중요 메일 요약 보고서", "", "1. **[팀장님] 서버 점검 안내** ..."],
          "created_at": "2026-03-11T13:49:07...",
          "modified_at": "2026-03-11T13:49:07..."
      }
  }

  → write_file로 저장한 파일이 State(메모리) 안에 존재합니다.
  → 하지만 이 프로세스가 종료되면 사라집니다!
  → Step 2에서 FilesystemBackend를 사용하면 디스크에 영구 저장됩니다.

  [DeepAgents 토큰 사용량]
  LLM 호출 횟수 : 4회
  입력 토큰     : 22,275
  출력 토큰     : 590
  합계          : 22,865
```

Agent가 `write_file`로 저장한 파일은 **디스크가 아닌 State 딕셔너리의 `files` 키**에 존재합니다. 기본 백엔드인 `StateBackend`는 인메모리이므로, 프로세스가 종료되면 파일도 사라집니다. Step 2에서 `FilesystemBackend`로 교체하여 이 문제를 해결합니다.

4회 호출에 입력 22K 토큰은 많아 보이지만, 내역은 다음과 같습니다.

원인	추정 토큰	비율
고정 오버헤드 (3,500 × 4회)	~14,000	63%
대화 기록 누적 (매 호출마다 이전 메시지 재전송)	~6,000	27%
Tool 결과 (메일 목록 JSON, 메일 본문 등)	~2,300	10%

고정 오버헤드 자체는 호출당 ~3,500이지만, **LLM API는 매 호출마다 전체 대화 기록을 재전송**하기 때문에 호출 횟수가 늘수록 누적 토큰이 빠르게 증가합니다. 이것이 Ch1에서 다룬 "Agent는 마지막 수단" 원칙의 실질적 근거입니다 — 단순한 작업에 Agent를 사용하면 Workflow 대비 토큰 비용이 수 배로 늘어납니다.

Anthropic이 제안한 Long-Running Agent 패턴

Anthropic은 아래 두 글에서 롱러닝 에이전트 설계 원칙을 설명합니다.

- Effective harnesses for long-running agents (2025-11-26)
- Building effective agents (2024-12-19)

특히 첫 번째 글은 초기화 전용 Agent와 실행 전용 Agent를 분리하는 2단계 패턴을 제안합니다.

이 패턴과 DeepAgents의 대응 관계는 다음처럼 이해하면 됩니다.

- Initializer 역할: `TodoListMiddleware`가 계획 생성/진행 상태를 구조화
- Executor 역할: `SubAgentMiddleware + FilesystemBackend`가 청크 단위 실행/아티팩트 저장 담당
- 결론: DeepAgents는 Anthropic의 2단계 아이디어를 "미들웨어 조합"으로 실무화한 형태에 가깝습니다.

2단계 아키텍처:

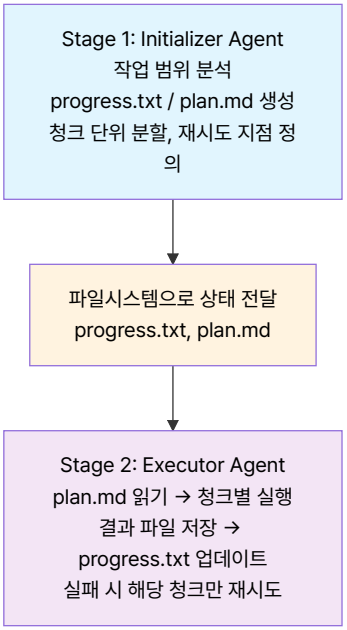

왜 두 단계로 나누는가?

단일 에이전트로 장시간 작업을 수행하면 4가지 문제가 발생합니다. 2단계 분리는 각각을 해결합니다.

단일 에이전트의 문제	2단계 분리의 해결	메커니즘
컨텍스트 소진 — 작업 도중 컨텍스트 창이 가득 차면 반쯤 구현된 상태로 중단됨	Initializer가 전체 계획을 파일로 외부화 → 새 세션이 즉시 상태 파악	`progress.txt`, `plan.md`
토큰 낭비 — 매 세션마다 "환경 파악 → 어디까지 했나 확인"에 토큰 소비	Initializer가 환경·테스트 방법을 미리 구축 → Executor 세션은 즉시 실행 가능	`init.sh`, 구조화된 작업 목록
실패 시 대량 복구 비용 — 코드가 깨지면 "기본 앱 되살리기"에 상당한 토큰 소비	git 커밋 + progress.txt → `git revert`로 즉시 복구, 해당 청크만 재시도	초기 커밋 + 기능별 커밋
거짓 완료 — 다음 세션 에이전트가 이전 작업물을 보고 "이미 끝났다"고 오판	구조화된 상태 파일이 정확한 진행 상황 전달	`progress.txt` = 단일 진실 공급원 (SSOT)

> 출처: Anthropic - Effective harnesses for long-running agents — Anthropic은 실제로 단일 에이전트가 "전체를 one-shot 시도 → 실패 → 복구 불능" 패턴에 빠지는 것을 관찰하고, 파일 기반 상태 전달로 해결했다고 보고합니다.

핵심 인사이트: 2단계 분리의 본질은 **LLM의 유한한 컨텍스트 창**이라는 근본 제약을 **파일시스템이라는 무한 외부 메모리**로 우회하는 것입니다. 이를 통해 토큰 효율, 작업 정확도, 실패 복구가 모두 개선됩니다.

DeepAgents의 `FilesystemBackend` + `TodoListMiddleware`는 이 패턴을 자동으로 구현합니다.

Checkpoint: Harness 개념 확인

다음 질문에 답해보세요.

1. "프롬프트 엔지니어링"과 "컨텍스트 엔지니어링"의 가장 큰 차이는?
2. Terminal Bench에서 같은 모델로 Top 30 밖→Top 5가 된 핵심 변인은?
3. Anthropic의 2단계 패턴에서 Initializer와 Executor를 분리하는 이유는?

먼저 직접 생각한 뒤, 아래 정답을 확인하세요.

정답:

1. 프롬프트 엔지니어링은 "이번 호출의 지시문 품질"에 집중하고, 컨텍스트 엔지니어링은 "컨텍스트 창 전체를 세션 간에 걸쳐 설계"하는 것입니다. 관심사가 단일 호출 → 전체 흐름으로 확장됩니다.
2. **Harness(미들웨어 스택)** 입니다. 모델(GPT-5.2-Codex)과 Runtime(LangGraph)은 동일한 상태에서 PreCompletionChecklist·LocalContext·LoopDetection 등 미들웨어를 추가·조정한 결과, 컨텍스트 창에 들어가는 정보의 질이 달라져 52.8% → 66.5%로 올랐습니다. 즉, **모델의 지능이 아니라 컨텍스트 설계가 성능을 결정**한 사례입니다.
3. 단일 에이전트는 장시간 작업 중 (a) 컨텍스트 소진으로 반쯤 구현된 채 중단되고, (b) 다음 세션이 상태를 모르므로 "이미 끝났다"고 오판하며, (c) 실패 시 복구에 대량 토큰을 소비합니다. 2단계 분리는 **계획을 파일로 외부화**하여 이 세 가지를 해결합니다: 새 세션이 progress.txt로 즉시 상태를 파악하고, git revert로 실패 청크만 되돌릴 수 있습니다.
4. 2단계 분리에는 **비용 최적화** 효과도 있습니다. 계획(Planner)에는 고성능 모델을, 실행(Executor)에는 저비용 모델을 배치하는 패턴이 업계 전반에서 활용됩니다.
   - **Anthropic**은 공식 블로그에서 Claude Opus를 리드 에이전트, Claude Sonnet을 서브에이전트로 구성한 멀티에이전트 시스템이 단일 Opus 대비 **90.2% 성능 향상**을 달성했다고 보고했습니다(Multi-Agent Research System, 2025). Haiku 4.5 발표에서는 "Sonnet이 복잡한 문제를 분해·계획하고, 다수의 Haiku가 서브태스크를 병렬 실행"하는 구조를 명시했습니다(Introducing Claude Haiku 4.5, 2025).
   - **Google DeepMind**의 AlphaEvolve도 Gemini Flash(탐색 폭 확보)와 Gemini Pro(깊이 있는 제안)를 앙상블로 조합합니다(AlphaEvolve, 2025).
   - 학술 연구에서도 KAIST의 COPE 프레임워크가 소형·대형 모델을 교차 배치하여 GPT-4o 단독 대비 **50~74% 비용 절감**과 동등 이상의 정확도를 달성했습니다(arXiv:2506.11578, 2025).

⏱ 13:28

Step 1: DeepAgents Agent 초기화 (30분)

> 📂 실습 코드: `ch3-deepagents/step1_init_agent.py`

▶ 실행:

```
uv run python3 ch3-deepagents/step1_init_agent.py
```

```
============================================================
Step 1-A: create_deep_agent() 기본 사용법
============================================================

[INFO] Agent 생성 완료
  - 모델: openai:google/gemini-3-flash-preview
  - 내장 Tool: read_file, write_file, edit_file, ls, glob, grep, execute, write_todos, task
  - 내장 Middleware: TodoList, Filesystem, SubAgent, Summarization

============================================================
Step 1-B: 커스텀 Tool과 함께 Agent 생성
============================================================

[INFO] 메일 Agent 생성 완료
  - 커스텀 Tool: check_inbox, get_email_detail
  - 내장 Tool: 자동 포함 (read_file, write_file, write_todos 등)

============================================================
Step 1-C: Agent 실행 - 메일 확인 및 요약
============================================================

--- Agent 최종 응답 ---
[
  {
    "type": "text",
    "text": "중요 메일 3건을 확인하고 각각의 상세 내용을 요약하여 `/mail_summary.md` 파일에 저장했습니다.\n
시\n- **워크숍(고객사 메일 본문 내용):** 12/20 진행, 12/15까지 회신\n- **미팅 요청(CEO 공지 메일 본문 내용
참고: 일부 메일의 제목과 상세 내용이 일치하지 않는 것으로 보입니다. 파일 내용을 확인해 주세요.*",
    "annotations": [],
    "id": "msg_tmp_eygstqzy9j"
  }
]
```

1.1 환경 확인

Ch2 Preflight에서 `uv sync`로 의존성을 이미 설치했고, `OPENROUTER_API_KEY`도 `.bashrc`에 설정되어 있습니다. 추가 설치 없이 바로 진행합니다.

```
# 설치 상태 확인 (선택)
uv run python3 -c "from deepagents import create_deep_agent; print('OK')"
```

1.2 기본 사용법

```python
from deepagents import create_deep_agent

# 이 한 줄로 Planning + Filesystem + Subagent 모두 포함!
agent = create_deep_agent(model="openai:google/gemini-3-flash-preview")

result = agent.invoke({
    "messages": [{"role": "user", "content": "메일 분석 보고서를 작성해줘"}]
})
```

`provider:model` 표기(예: `openai:google/gemini-3-flash-preview`)는 provider 라우팅을 명시하는 형태입니다. `openai:` 프리픽스는 OpenAI 호환 API(OpenRouter 포함)를 뜻합니다. 같은 패턴으로 `anthropic:...` 등으로 교체할 수 있으며, 실제 지원 목록은 설치된 provider 패키지/문서를 기준으로 확인합니다.

1.3 기본 제공 도구 확인

`create_deep_agent()` 를 호출하면 다음 Tool이 자동으로 Agent에 연결됩니다.

Tool	출처	설명
`write_todos`	TodoListMiddleware	작업 목록 관리
`ls`	FilesystemMiddleware	디렉토리 목록
`read_file`	FilesystemMiddleware	파일 읽기
`write_file`	FilesystemMiddleware	파일 쓰기
`edit_file`	FilesystemMiddleware	파일 부분 수정
`glob`	FilesystemMiddleware	파일 패턴 검색
`grep`	FilesystemMiddleware	파일 내용 검색
`execute`	FilesystemMiddleware	셸 명령 실행 (SandboxBackend 필요)
`task`	SubAgentMiddleware	하위 Agent 위임

참고: 위 Tool들은 미들웨어 내부에 등록되어 `agent.tools` 로는 직접 접근할 수 없습니다. 실제 동작은 `agent.invoke()` 로 확인합니다 — Agent에게 "파일을 저장해줘"라고 요청하면 `write_file` 이, "계획을 세워줘"라고 요청하면 `write_todos` 가 자동으로 호출됩니다.

1.4 커스텀 Tool 추가

```python
from langchain_core.tools import tool

@tool
def check_inbox(filter: str = "unread") -> str:
    """메일함의 메일을 확인합니다."""
    # ... 구현 ...

agent = create_deep_agent(
    model="openai:google/gemini-3-flash-preview",
    tools=[check_inbox],  # 커스텀 Tool 추가
    system_prompt="당신은 메일 관리 비서입니다.",
)
```

Step 1 성공 기준

- `create_deep_agent()` 호출이 에러 없이 완료된다.
- Agent에게 간단한 요청을 보내면(`invoke`) 응답이 정상 반환된다.
- 커스텀 Tool(`check_inbox`)을 추가한 Agent가 정상 생성된다.

직접 구성해 볼까요? (5분)

`code/ch3-deepagents/notebooks/harness_fill_in_blank.ipynb` 을 열고 **실험 1**을 진행하세요.

`create_deep_agent(model=___, tools=[___], system_prompt=___)` 의 빈칸을 채우고, `invoke()` 로 Agent가 정상 동작하는지 확인합니다.

1.5 Ch2와 비교

```
# Ch2: ~30줄의 그래프 구성
builder = StateGraph(MessagesState)
builder.add_node("llm", call_model)
builder.add_node("tools", ToolNode(tools))
builder.add_edge(START, "llm")
builder.add_conditional_edges("llm", tools_condition)
builder.add_edge("tools", "llm")
graph = builder.compile(checkpointer=MemorySaver())

# DeepAgents: 1줄
agent = create_deep_agent(model="openai:google/gemini-3-flash-preview", tools=[check_inbox])
```

⏱ 13:40

Step 2: Filesystem 백엔드 활용 (20분)

> 📂 실습 코드: `ch3-deepagents/step2_filesystem.py`

▶ 실행:

```
uv run python3 ch3-deepagents/step2_filesystem.py
```

2.1 왜 Filesystem이 중요한가?

Ch2 Step4에서 경험한 문제: **컨텍스트 윈도우를 넘는 데이터를 처리하려면 외부 저장소가 필요**

DeepAgents는 **Backend** 시스템으로 이를 해결합니다.

2.2 StateBackend (기본값, In-Memory)

```
# 기본값 — 별도 설정 불필요
agent = create_deep_agent(model="openai:google/gemini-3-flash-preview")
# 파일이 Agent 상태(state["files"])에 저장됨
# 같은 thread 내에서만 유지, 세션 종료 시 사라짐
```

2.3 FilesystemBackend (로컬 디스크)

```
from deepagents import create_deep_agent
from deepagents.backends import FilesystemBackend

agent = create_deep_agent(
    model="openai:google/gemini-3-flash-preview",
    backend=FilesystemBackend(root_dir="./workspace", virtual_mode=True)
)
# 파일이 실제 디스크에 저장됨
# 세션이 종료되어도 유지
# virtual_mode=True → 디렉토리 탈출 방지 (보안)
```

2.4 StoreBackend (영구 저장, 스레드 간 공유)

```
from deepagents.backends import StoreBackend

agent = create_deep_agent(
    model="openai:google/gemini-3-flash-preview",
    backend=StoreBackend,  # BackendFactory — runtime 주입 시 자동 생성
)
# 파일이 LangGraph의 BaseStore에 저장됨
```

```
# 대화(thread)가 바뀌어도 유지 — 에이전트의 장기 메모리에 적합
# BaseStore 구현체(InMemoryStore, PostgresStore 등)에 따라 실제 저장소 결정
```

`StateBackend` 는 같은 대화 안에서만 파일이 유지되지만, `StoreBackend` 는 **대화를 넘어** 파일이 유지됩니다. 운영 환경에서 `PostgresStore` 를 BaseStore로 연결하면 DB 기반 영구 저장이 됩니다.

2.5 LocalShellBackend (파일시스템 + 셸 실행)

```
from deepagents.backends import LocalShellBackend

agent = create_deep_agent(
    model="openai:google/gemini-3-flash-preview",
    backend=LocalShellBackend(
        root_dir="./workspace",
        virtual_mode=True,
        timeout=120.0,           # 셸 명령 타임아웃 (초)
        max_output_bytes=100_000, # 출력 크기 제한
    ),
)
# FilesystemBackend의 모든 기능 + execute()로 셸 명령 실행
# 샌드박싱 없음 — 개발/테스트 환경 전용
```

`LocalShellBackend` 는 `FilesystemBackend` 를 상속하면서 `execute()` 메서드를 추가합니다. Agent가 `bash` Tool로 셸 명령을 실행할 수 있게 됩니다. 호스트에서 직접 실행되므로 **샌드박싱이 없습니다** — 개발/CI 환경 전용입니다. 운영 환경에서 격리된 셸 실행이 필요하면 DeepAgents CLI의 `--sandbox` 옵션으로 원격 샌드박스 프로바이더를 연결합니다. 현재 Daytona, Modal, Runloop 세 프로바이더가 파트너 패키지로 제공됩니다(공식 문서).

2.6 CompositeBackend (하이브리드)

```
from deepagents.backends import CompositeBackend, StateBackend, FilesystemBackend

composite = lambda rt: CompositeBackend(
    default=StateBackend(rt),               # 기본: 메모리
    routes={
        "/memories/": FilesystemBackend(     # /memories/ 경로 → 디스크
            root_dir="./agent_memory",
            virtual_mode=True,
        ),
    },
)
# rt는 ToolRuntime으로, StateBackend/StoreBackend처럼 런타임 컨텍스트가 필요한 백엔드에서 사용
agent = create_deep_agent(model="openai:google/gemini-3-flash-preview", backend=composite)
```

경로 프리픽스별로 서로 다른 백엔드를 연결합니다. 위 예시에서 `/memories/notes.txt` 는 디스크에, 나머지 경로는 메모리에 저장됩니다.

2.7 Backend 전체 정리

백엔드	저장소	영속성	셸 실행
`StateBackend`	LangGraph 상태	휘발 (스레드 내)	×
`FilesystemBackend`	호스트 디스크	영구	×
`StoreBackend`	LangGraph BaseStore	영구 (스레드 간)	×
`LocalShellBackend`	호스트 디스크	영구	✓ (비격리)
`CompositeBackend`	경로별 라우팅	하위 백엔드 따름	하위 따름
원격 샌드박스 (Daytona, Modal, Runloop)	원격 컨테이너/VM	프로바이더 따름	✓ (격리)

위 5개(`State` ~ `CompositeBackend`)가 SDK 내장 구현체입니다. 운영 환경의 격리 실행이 필요하면 `--sandbox daytona` 등으로 원격 샌드박스 프로바이더를 연결합니다. 모든 백엔드는 `BackendProtocol` (`ls_info()` , `read()` , `write()` , `edit()` 등 8개 파일 조작 메서드)을 구현하며, 셸 실행이 필요한 백엔드는 `SandboxBackendProtocol` (`execute()` 추가)을 구현합니다.

`lambda rt` 기반 CompositeBackend는 **고급 옵션**입니다. Ch4/Ch5 완주에는 필수가 아니며, 초급자는 `FilesystemBackend` 단일 구성만 사용해도 됩니다.

실행 후 확인: step2 스크립트를 실행하면 FilesystemBackend로 메일 분석 결과를 디스크에 저장합니다. `./workspace/ch3/` 디렉토리에 파일이 생성되면 정상입니다. Step 1(StateBackend)에서는 State 딕셔너리 안에만 파일이 존재했던 것과 비교해 보세요.

Step 2 성공 기준

- FilesystemBackend Agent 실행 후 `./workspace/ch3/` 디렉토리에 실제 파일이 생성된다.
- Step 1의 StateBackend(메모리 전용)와의 차이를 이해한다.

> **Backend 차이를 실험해 볼까요? (10분)**
>
> `code/ch3-deepagents/notebooks/harness_fill_in_blank.ipynb` 을 열고 **실험 2**를 진행하세요.
>
> `FilesystemBackend(root_dir=___, virtual_mode=___)` 의 빈칸을 채워 디스크 저장 Agent를 구성합니다.

2.5 Agent가 자동으로 파일을 활용하는 예시

```
# Agent에게 복잡한 작업을 주면, 자동으로 파일시스템을 활용합니다
result = agent.invoke({
    "messages": [{"role": "user", "content":
        "메일 100통의 카테고리별 통계를 분석해줘. "
        "중간 결과는 파일에 저장하면서 진행해."}]
})

# Agent의 행동:
# 1. write_todos → 작업 계획 수립
# 2. write_file("batch_1_analysis.md", ...) → 중간 결과 저장
# 3. write_file("batch_2_analysis.md", ...) → 중간 결과 저장
# 4. read_file("batch_1_analysis.md") → 이전 결과 로드
# 5. write_file("final_report.md", ...) → 최종 보고서
```

⏱ 13:48 – 쉬는 시간

⏱ 13:50~14:00 쉬는 시간

⏱ 14:00 – 시작

Step 3: Planning 도구 활용 (20분)

> 📂 실습 코드: `ch3-deepagents/step3_planning.py`
>
> ▶ 실행:

```
uv run python3 ch3-deepagents/step3_planning.py
```

3.1 write_todos 동작 방식

`TodoListMiddleware` 가 시스템 프롬프트에 Planning 지침을 자동 주입합니다. Agent는 복잡한 작업을 받으면 자동으로 `write_todos` 를 호출하여 계획을 세웁니다.

3.2 TODO 상태 관리

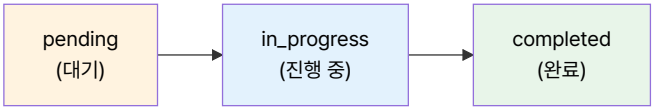

3.3 Agent의 Planning 행동 패턴

```
사용자: "메일 100통을 분석해서 보고서를 만들어줘"

Agent 행동:
1. write_todos([
     {"content": "메일 배치 수집", "status": "pending"},
     {"content": "카테고리별 분류", "status": "pending"},
     {"content": "중요도 분석", "status": "pending"},
     {"content": "최종 보고서 작성", "status": "pending"},
   ])

2. write_todos([
     {"content": "메일 배치 수집", "status": "in_progress"},  ← 시작
     ...
   ])
   → fetch_emails 호출, write_file로 결과 저장

3. write_todos([
     {"content": "메일 배치 수집", "status": "completed"},    ← 완료
     {"content": "카테고리별 분류", "status": "in_progress"},  ← 다음
     ...
   ])
   → 분류 작업 수행

4. ... (반복)

5. 모든 TODO가 completed → 최종 답변 반환
```

실행 후 확인: step3 스크립트를 실행하면 Agent가 `write_todos`를 호출하여 작업 계획을 세우는 것이 로그에 출력됩니다. TODO 상태가 `pending` → `in_progress` → `completed`로 변하는 흐름을 확인하세요.

Step 3 성공 기준

- Agent가 자동으로 `write_todos`를 호출하여 작업 계획을 생성한다.
- TODO 항목의 상태가 순차적으로 변경되는 것을 로그에서 확인한다.
- Ch2에서 직접 구현한 `write_todos` Tool 없이도 동일한 기능이 동작한다.

TODO 상태를 예측해 볼까요? (2분)

Agent에게 "메일 20통을 분석해서 보고서를 만들어줘"라고 요청했을 때, `write_todos`의 **첫 번째 호출**에서 TODO 항목은 몇 개가 생성될까요? 각 항목의 초기 상태는?

1. 종이에 예상 TODO 목록(항목 수 + 상태)을 적어 보세요.
2. `step3_planning.py`를 실행하여 실제 로그와 비교합니다.
3. **예측과 실제가 다른 부분**이 있다면: Agent가 왜 그렇게 계획했는지 생각해 보세요.

3.4 Ch2 Step4와 비교

```python
# Ch2: TODO Tool을 직접 구현해야 함 (30줄)
@tool
def write_todos(todos: str) -> str:
    todo_list = json.loads(todos)
    with open(TODO_FILE, "w") as f:
        json.dump(todo_list, f)
    pending = sum(1 for t in todo_list if t["status"] == "pending")
    ...

# DeepAgents: TodoListMiddleware가 자동 제공
# 시스템 프롬프트도 자동 주입, 상태 스키마도 자동 확장
agent = create_deep_agent()  # write_todos 이미 포함!
```

Step 4: 간단한 스케줄/반복 실행(폴링) 구성 (20분)

> 📂 실습 코드: `ch3-deepagents/step4_polling.py`
>
> ▶ 실행:

```
uv run python3 ch3-deepagents/step4_polling.py
```

4.1 Long-Running Agent를 위한 폴링

Ch1에서 배운 Long-Running Agent의 핵심: **단일 LLM 호출을 넘어, 주기적으로 반복 실행**

```
"매일 아침 9시에 메일함을 확인하고, 중요 메일이 있으면 알려줘"
```

폴링과 스케줄링은 구분해서 이해해야 합니다.

- **폴링(Polling)**: `asyncio.sleep(간격)`으로 고정 주기(예: 5분마다) 반복 실행
- **스케줄링(Scheduling)**: cron/APScheduler처럼 특정 시각(예: 매일 09:00)에 실행

이 절의 실습 코드는 **폴링**입니다. 스케줄링은 cron이나 APScheduler 같은 외부 도구와 조합하여 구현하며, 이 교재에서는 폴링 패턴에 집중합니다.

4.2 폴링 패턴 구현

핵심 구조만 추출하면 다음과 같습니다 (실습 코드 `step4_polling.py`는 Mock 메일 시스템과 함께 더 풍부한 버전입니다).

```python
import asyncio
from deepagents import create_deep_agent
from langgraph.checkpoint.memory import MemorySaver
from langchain_core.tools import tool

@tool
def check_new_emails() -> str:
    """마지막 확인 이후 도착한 새 메일을 가져옵니다."""
    # 실습 코드에서는 전역 MAIL_STORE에서 새 메일을 필터링
    return '{"new_count": 1, "summary": "긴급 메일 1통"}'

agent = create_deep_agent(
    model="openai:google/gemini-3-flash-preview",
    tools=[check_new_emails],
    checkpointer=MemorySaver(),  # 세션 간 대화 상태 유지
)

async def polling_loop(interval_seconds=5, max_polls=3):
    """주기적으로 Agent를 실행하는 폴링 루프."""
    config = {"configurable": {"thread_id": "mail-poller"}}

    for poll_num in range(1, max_polls + 1):
        result = await agent.ainvoke(
            {"messages": [{"role": "user", "content":
                "새 메일이 있는지 확인하고, 중요한 것이 있으면 알려줘."}]},
            config=config,  # 동일한 thread_id → 이전 상태 이어서
        )

        last_msg = result["messages"][-1]
        print(f"[폴링 #{poll_num}] {last_msg.content[:100]}")

        if poll_num < max_polls:
            await asyncio.sleep(interval_seconds)

asyncio.run(polling_loop(interval_seconds=5, max_polls=3))
```

4.3 Checkpointer로 세션 간 연속성

```python
# 같은 thread_id를 사용하면:
# - 이전 체크 결과를 기억
# - "이전에 확인한 메일은 다시 알리지 마세요" 같은 지시 가능
# - 점진적으로 컨텍스트 축적

config = {"configurable": {"thread_id": "mail-poller"}}

# 첫 번째 실행: 메일 3통 확인
# 두 번째 실행: "이전에 확인한 3통 외에 새 메일이 있나요?"
# 세 번째 실행: 누적된 맥락을 활용
```

주의: `MemorySaver`는 프로세스 메모리에 저장되므로, 프로세스 재시작 시 상태가 사라집니다. 운영 환경에서는 SQLite/Postgres checkpointer를 사용하세요.

실행 후 확인: step4 스크립트를 실행하면 5초 간격으로 메일 체크를 반복합니다. 3회 반복 후 자동 종료됩니다. 로그에서 `[폴링 #1]`, `[폴링 #2]`, `[폴링 #3]` 메시지를 확인하세요.

Step 4 성공 기준

- 폴링 루프가 지정 간격으로 반복 실행된다.
- 같은 `thread_id`를 사용하여 이전 대화 맥락이 유지된다.
- `Ctrl+C`로 안전하게 종료할 수 있다.

4.4 HITL (Human-in-the-Loop) — `interrupt_on`

`create_deep_agent()`의 **SDK 호출에서 HITL은 선택적**입니다. `interrupt_on` 파라미터를 명시적으로 전달해야 활성화됩니다.

```python
@tool
def forward_email(email_id: int, to: str) -> str:
    """메일 전달 Tool (개념 예시용 stub)."""
    return f"{email_id}번 메일을 {to}에게 전달했습니다."

agent = create_deep_agent(
    model="openai:google/gemini-3-flash-preview",
    tools=[check_new_emails, forward_email],
    checkpointer=MemorySaver(),   # interrupt 상태 저장용, 필수
    interrupt_on={
        "forward_email": True,    # 메일 전달 전 사람 승인 필요
    },
)
```

`interrupt_on`이 전달되면 내부적으로 `HumanInTheLoopMiddleware`가 자동 생성되어 미들웨어 스택에 추가됩니다. Ch2에서 `interrupt()`를 직접 호출한 것과 달리, 여기서는 **Tool 이름만 지정하면 해당 Tool 호출 전에 자동으로 중단**됩니다.

> **SDK vs CLI의 차이**: DeepAgents CLI(`deepagents` 명령)에서는 `execute`, `write_file`, `edit_file` 등 부작용이 있는 도구에 HITL이 **기본 활성화**되어 있습니다. `--auto-approve` 플래그로 비활성화할 수 있습니다. SDK를 직접 사용하는 이 교재의 실습에서는 opt-in 방식입니다.

4.5 DeepAgents CLI 소개

지금까지 Python SDK(`create_deep_agent()`)를 직접 호출했지만, DeepAgents는 **Claude Code에서 영감받은 터미널 기반 대화형 인터페이스**도 제공합니다.

```python
# 별도 패키지 설치
uv tool install deepagents-cli

# 실행 - Textual 기반 TUI가 시작됨
deepagents
```

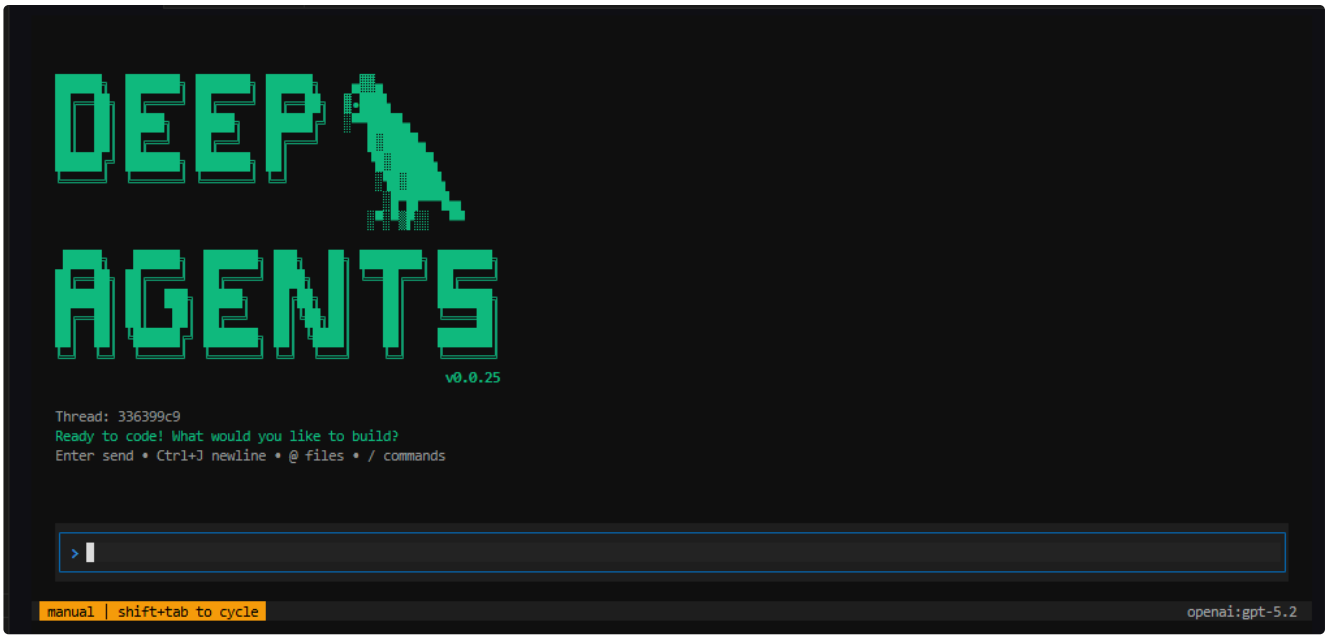

기능	설명
슬래시 명령어	`/help`, `/clear`, `/remember` (대화→메모리 저장), `/tokens`
파일 멘션	`@filename` 으로 파일을 컨텍스트에 추가 (자동완성 지원)
셸 실행	`!command` 로 로컬 bash 명령어 실행
HITL 기본 활성화	부작용 있는 도구 호출 전 자동 승인 요청
비인터랙티브 모드	`deepagents -n "테스트 실행해줘"`

CLI는 SQLite checkpointer를 자동으로 설정하므로 대화가 세션 간에 유지됩니다. SDK로 커스텀 워크플로우를 구축할 때와, CLI로 빠르게 대화형 작업을 수행할 때를 구분하여 사용합니다.

> 이 교재에서는 Agent의 내부 동작 이해를 위해 SDK 중심으로 실습하지만, 실무에서는 CLI가 더 빠른 진입점이 됩니다.

⏱ 14:38

핵심 요약

Step	Ch2 (수동)	Ch3 (DeepAgents)
파일시스템	save_to_file/read_from_file 직접 구현	FilesystemBackend + 내장 Tool
Planning	write_todos/read_todos 직접 구현	TodoListMiddleware 자동 제공
Subagent	미구현	SubAgentMiddleware + task Tool
컨텍스트 관리	MAX_ITERATIONS 하드코딩	SummarizationMiddleware
그래프 구성	StateGraph 30줄	create_deep_agent() 1줄

DeepAgents의 핵심 가치:

> "Agent 개발자가 비즈니스 로직에만 집중할 수 있게, 공통 인프라를 Harness가 제공한다."

SummarizationMiddleware는 `create_deep_agent()` 기본 스택에 포함되며, 대화가 길어져 컨텍스트가 커질 때 자동으로 요약을 적용합니다. 이 챕터는 개념 소개 중심으로 다루고, 상세 튜닝(트리거 기준/보존 메시지 수)은 참고 자료의 Customization 문서에서 확장합니다.

요약 발생 여부는 다음처럼 확인합니다.

1. 실행 로그에서 요약 미들웨어 이벤트(요약 시작/완료) 확인
2. 요약 직전/직후의 messages 길이(또는 토큰 추정치) 비교
3. 핵심 식별자(이메일 ID/정책 키워드)가 요약 이후에도 보존되는지 샘플 검증

요약 정책 가이드:

- **요약 금지(원문 유지)**: 정책/규정 문장, 식별자(ID/계정/주문번호), 감사 로그
- **요약 허용**: 반복 대화, 중간 사고흐름, 장문의 일반 설명

```
Ch2의 여정: 수동 루프 → LangGraph → 체크포인트 → Long-Running (힘들다!)
Ch3의 해결: create_deep_agent() → 모든 보일러플레이트 해결

다음 단계: Skills와 MCP로 "메일 체크" 도메인 지식을 모듈화 →
```

> **다음 Chapter**: Skills로 절차적 지식을 모듈화하고, MCP로 실제 메일 서버에 연결합니다.

⏱ 14:48 – 쉬는 시간

⏱ 14:50~15:00 쉬는 시간

실습 트러블슈팅 (FAQ)

Q1. `uv add deepagents` 가 실패합니다.

- DeepAgents는 LangChain 팀의 비교적 최근 프로젝트입니다. 먼저 최신 버전을 확인하세요.
- `uv add deepagents` 또는 `uv add "deepagents>=0.4"`
- 설치 후 확인: `uv run python3 -c "from deepagents import create_deep_agent; print('OK')"`
- 네트워크 문제라면 `uv pip install --index-url https://pypi.org/simple/ deepagents`

Q2. `create_deep_agent()` 호출 시 LLM 인증 오류가 납니다.

- `OPENROUTER_API_KEY` 환경변수가 설정되었는지 확인하세요.
- `echo $OPENROUTER_API_KEY` 로 빈 값이 아닌지 확인합니다.
- 키가 만료되었거나 잘못된 경우 OpenRouter 대시보드에서 새 키를 발급하세요.

Q3. `FilesystemBackend` 사용 시 파일이 생성되지 않습니다.

- `root_dir` 경로가 존재하는지 확인하세요.
- `virtual_mode=True` 일 때 Agent가 `root_dir` 바깥 경로에 쓰기를 시도하면 조용히 차단됩니다.
- 확인: `ls ./workspace/` 로 디렉토리 존재 여부 점검

Q4. Step4 폴링 실행이 멈추지 않습니다.

- `Ctrl+C` 로 종료합니다.
- 초급자 안전 버전(`polling_loop_safe`)은 `max_cycles=3` 으로 자동 종료됩니다.
- `asyncio.run()` 이 아닌 `await` 로 실행한 경우 종료가 어려울 수 있습니다. 터미널을 닫고 다시 시작하세요.

Q5. `async/await` 구문 관련 에러가 납니다.

- Step4의 폴링 코드는 `asyncio` 기반입니다. Python 3.10 이상이 필요합니다.
- Jupyter Notebook에서 실행할 경우 `asyncio.run()` 대신 `await` 를 직접 사용하세요.
- 터미널에서 `uv run python3 ch3-deepagents/step4_polling.py` 로 실행하면 정상 동작합니다.

참고 자료

- DeepAgents GitHub
- DeepAgents 개요
- DeepAgents Quickstart
- DeepAgents Customization
- Using Skills with Deep Agents
- Deep Agents Middleware
- DeepAgents Backends
- LangChain - Context Engineering for Agents
- LangChain - Improving Deep Agents with harness engineering
- Anthropic - Effective harnesses for long-running agents

- Anthropic - Building effective agents
- OpenAI - Harness Engineering: Leveraging Codex — JSON-RPC 기반 Items/Turns/Threads, Harness 실무 사례
- Martin Fowler - Harness Engineering — Harness 3대 범주 정의
- Terminal Bench — 터미널 환경 AI Agent 벤치마크
- Anthropic - Effective context engineering for AI agents — Context Engineering 정의·전략
- Tobi Lutke on X — "Context Engineering" 용어 제안 (2025)
- Anthropic - Multi-Agent Research System (2025) — Opus(리드)+Sonnet(서브에이전트) 90.2% 성능 향상
- Introducing Claude Haiku 4.5 (Anthropic, 2025) — Sonnet(플래너)+Haiku(워커) 병렬 실행 구조
- AlphaEvolve (Google DeepMind, 2025) — Gemini Flash+Pro 앙상블
- COPE: Efficient LLM Collaboration via Planning (KAIST, arXiv:2506.11578) — 소형·대형 모델 교차 배치, 50~74% 비용 절감