Chapter 5. A2A로 역할 분리

Chapter 5. A2A로 역할 분리

> **학습 목표**
>
> - ◯ A2A 프로토콜의 핵심 개념(Task, Artifact, Agent Card)을 설명할 수 있다
> - ◯ A2A(Agent↔Agent 수평)와 MCP(Agent→Tool 수직)의 역할 차이를 비교할 수 있다
> - ◯ A2A의 동기/비동기 통신 패턴(블로킹, 폴링, 스트리밍, 웹훅)을 설명할 수 있다
> - ◯ Agent Card를 작성하고 `/.well-known/agent-card.json`으로 게시할 수 있다
> - ◯ 2개 Agent(Check ↔ Notify) 간 A2A 통신을 구현하고 동작 흐름을 추적할 수 있다

소요시간	학습방법
1.2h	이론/실습

⏱ 16:00 – 시작

이 챕터의 출발점

Ch4에서 Skills("어떻게")와 MCP("무엇에")를 분리했습니다. 메일을 확인하고 요약하는 Agent 하나를 만들었습니다.

여기에 알림 전송 기능을 추가한다고 가정합니다. 우리 팀이 전부 개발한다면 같은 Agent에 슬랙 알림 코드를 추가하면 됩니다 — 별도 프로토콜까지는 과합니다.

하지만 현실에서는 다릅니다. **메일 시스템은 커뮤니케이션팀이, 알림 시스템은 인프라팀이** 각각 운영합니다. 팀마다 배포 주기가 다르고, 내부 구현을 서로 알 필요도 없습니다. 외부 파트너사의 알림 서비스를 연동한다면 코드를 공유하는 것 자체가 불가능합니다.

이런 상황에서 **각 팀이 독립적으로 개발·배포한 Agent끼리 표준화된 방식으로 소통**할 수 있어야 합니다. 이것이 A2A가 필요한 이유입니다.

역할	Agent	운영 주체 (예시)
메일 확인	Check Agent (:9501)	커뮤니케이션팀
알림 전송	Notify Agent (:9502)	인프라팀 / 외부 SaaS

Agent 간 통신에는 **A2A(Agent-to-Agent)** 프로토콜을 사용합니다. MCP가 "Agent→Tool"이었다면, A2A는 "Agent↔Agent"입니다. 서로의 내부 구현을 모르는 Agent가 Agent Card(자기소개)만 보고 협업할 수 있는 구조입니다.

⏱ 16:03

이론: A2A 프로토콜 (20분)

MCP vs A2A: 역할이 다르다

Ch4에서 배운 MCP와 오늘 배울 A2A는 경쟁 관계가 아니라 **다른 계층의 보완 표준**입니다. 2025년 6월 A2A(Google)가 Linux Foundation 프로젝트로 기부되었고, 같은 해 12월 MCP(Anthropic)·AGENTS.md(OpenAI)·goose(Block)가 AAIF(Linux Foundation 산하)에 기부되어 같은 거버넌스 아래 공존하게 되었습니다.

```
MCP: Agent → Tool/Data  (수직)
     "내가 어떤 도구를 쓸 것인가?"

A2A: Agent ↔ Agent  (수평)
     "나와 다른 Agent가 어떻게 협업할 것인가?"
```

비유하면, MCP는 **직원이 사내 시스템(메일서버, DB)에 로그인하는 것**이고, A2A는 **다른 부서 담당자에게 업무를 요청하는 것**입니다. Notify Agent가 내부적으로 Slack API에 접근할 때는 MCP를 쓸 수 있지만, Check Agent가 Notify Agent에게 "이 메일 알림 보내줘"라고 요청하는 것은 A2A입니다. 두 프로토콜은 한 시스템 안에서 자연스럽게 공존합니다.

아래 그림은 A2A 프로토콜 공식 문서에서 두 표준의 관계를 보여주는 다이어그램입니다.

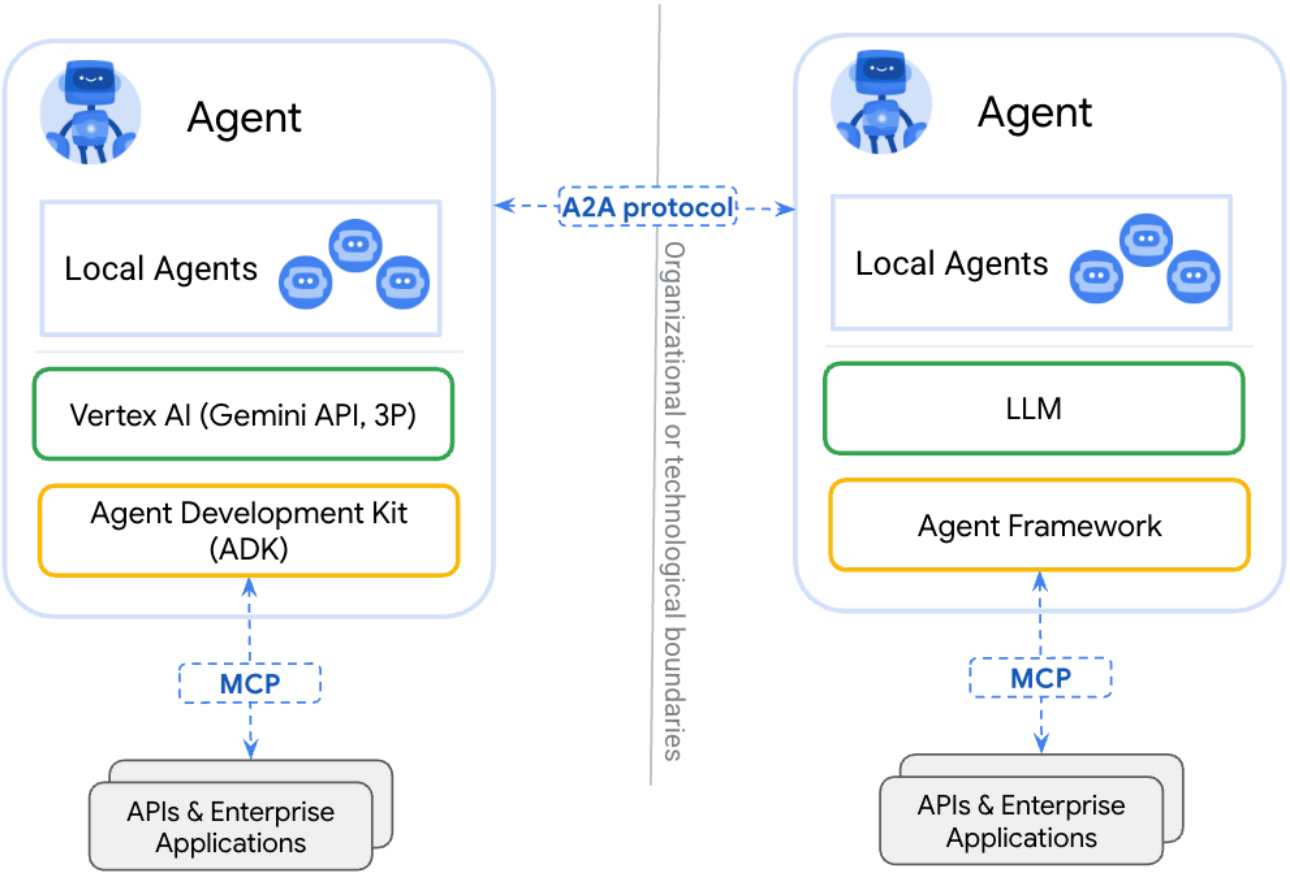

> 출처: A2A Protocol 공식 문서. Framework(예: ADK)로 Agent를 만들고, MCP로 도구를 장착하고, A2A로 다른 Agent와 통신하는 구조입니다.

A2A란?

A2A(Agent-to-Agent) 는 Google이 주도하여 만든 Agent 간 통신 프로토콜입니다.

> "MCP가 Agent→Tool 연결이라면, A2A는 Agent↔Agent 연결이다."

A2A vs MCP 비교

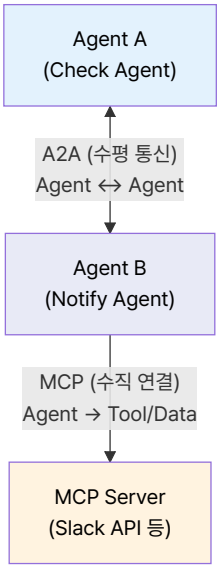

구분	A2A	MCP
방향	수평 (Agent ↔ Agent)	수직 (Agent → Tool)

구분	A2A	MCP
역할	Agent 간 협업	Agent의 도구 사용
단위	Task (작업 요청)	Tool Call (함수 호출)
발견	Agent Card	Tool Schema
프로토콜	JSON-RPC / gRPC / REST (3가지 동등 바인딩)	JSON-RPC over stdio/HTTP
주도	Google → Linux Foundation	Anthropic → Linux Foundation

> **참고: ACP(Agent Communication Protocol)의 합류와 A2A의 REST 바인딩**
>
> A2A는 원래 **JSON-RPC 2.0만** 지원했습니다. 한편 IBM Research가 BeeAI 플랫폼용으로 만든 **ACP**는 순수 REST(HTTP GET/POST/DELETE) 기반으로, SDK 없이 cURL만으로 Agent와 통신할 수 있었습니다.
>
> 2025년 6월 A2A v0.2.2에 REST 바인딩이 추가되었고, 같은 해 8월 ACP 팀은 A2A와 통합을 선언하며 개발을 중단했습니다. IBM의 Kate Blair(Director of Incubation, IBM Research)가 A2A 기술 운영위원회(TSC)에 합류했습니다.
>
> 그 결과 현재 A2A RC v1.0은 **JSON-RPC / gRPC / REST 세 가지 프로토콜 바인딩을 동등하게** 지원합니다. Agent는 이 중 하나 이상만 구현하면 됩니다. REST 바인딩 덕분에 `curl -X POST /message:send` 처럼 별도 SDK 없이도 Agent에 작업을 요청할 수 있습니다.

바인딩	특징	적합한 상황
JSON-RPC 2.0	A2A 초기 바인딩, 양방향 RPC	기존 A2A 에코시스템 호환
gRPC	Protocol Buffers, 고성능	대량 트래픽, 마이크로서비스
HTTP+JSON (REST)	표준 HTTP 동사, cURL 호환	빠른 프로토타이핑, 외부 연동

> 출처: ACP Joins Forces with A2A (LF AI & Data, 2025-08-29), IBM Think: ACP, A2A RC v1.0 Spec

> 보충: "수평/수직"은 본질 제약이 아니라 **주된 사용 패턴**을 설명하는 표현입니다. 실무에서는 혼합 구조(Agent 뒤 MCP, MCP 뒤 Agent)가 자주 등장합니다.

실사례: Elasticsearch 디지털 뉴스룸 (6-Agent 시스템)

> 출처: Elasticsearch Labs Blog

MCP + A2A가 함께 동작하는 가장 명확한 실사례입니다.

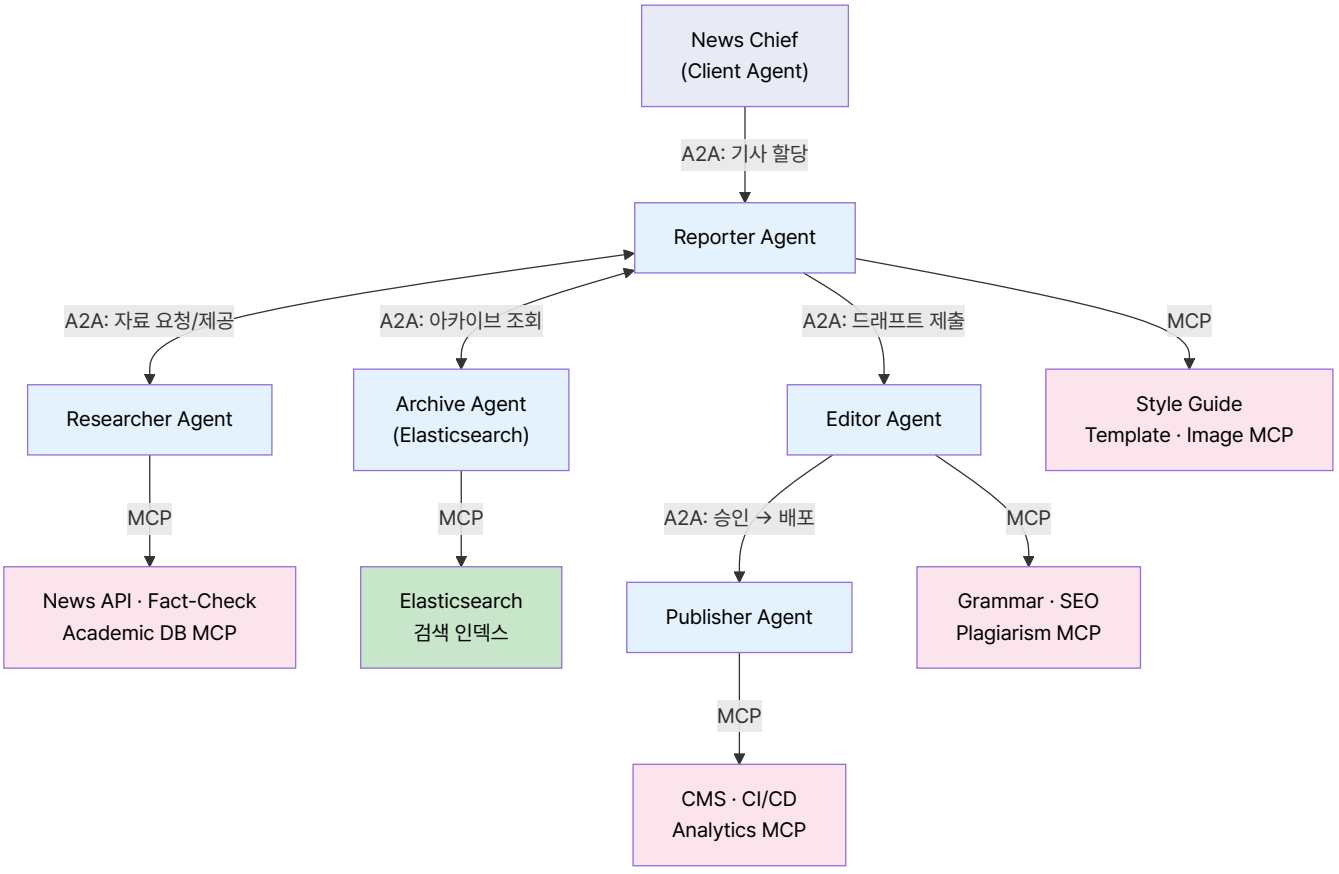

에이전트 역할 (6개):

Agent	역할	A2A 역할
News Chief	기사 할당, 워크플로 감독	A2A Client (Client Agent)
Reporter	기사 작성, 다른 Agent에게 자료 요청	A2A Server (Remote Agent)
Researcher	팩트·통계·배경 정보 수집	A2A Server (Remote Agent)
Archive	Elasticsearch로 과거 기사 검색·트렌드 분석	A2A Server (Remote Agent)
Editor	문법·스타일·SEO 검수	A2A Server (Remote Agent)
Publisher	CI/CD로 블로그 배포	A2A Server (Remote Agent)

프로토콜 역할 분담:

- **A2A**: News Chief → Reporter → Researcher/Archive (자료 수집) → Editor (검수) → Publisher (배포) 체인. Remote Agent끼리도 직접 통신합니다.
- **MCP**: 각 Agent가 자기 도구에 접근 (뉴스 API, 문법 검사기, CMS, Elasticsearch 등)

판단 기준 (실무 적용):

> "두 컴포넌트가 협상하고, 반복하고, 작업 상태를 유지해야 한다면 → A2A
> 한 컴포넌트가 외부 도구나 데이터에 접근해야 한다면 → MCP"

블로그 원문은 이 점을 강조합니다: Reporter가 팩트에 대한 확신이 낮으면 Researcher에게 **다시 돌아가** 추가 자료를 요청할 수 있고, Editor가 수정을 요구하면 Reporter가 **반복 작업**합니다. 이런 양방향 반복이 가능한 것이 단순 함수 호출(MCP)과 다른 A2A의 핵심 가치입니다.

A2A 핵심 개념 (필요 최소)

개념	설명	우리 시나리오
Client Agent	작업을 **요청하는** Agent. A2A 메시지의 `role: "user"`	테스트 스크립트, 또는 Check Agent가 Notify를 호출할 때
Remote Agent	요청을 **받아 처리하는** Agent. A2A 메시지의 `role: "agent"`	Check Agent(:9501), Notify Agent(:9502)
Agent Card	Agent의 자기소개 (8개 필수 필드: name, description, version, supportedInterfaces, capabilities, defaultInputModes, defaultOutputModes, skills)	Check Agent, Notify Agent 각각
Task	Agent에게 보내는 작업 요청	"이 중요 메일을 알림 보내줘"
Artifact	Task의 결과물	"슬랙 알림 전송 완료"
Skill	Agent가 수행 가능한 능력	"메일 확인", "알림 전송"
Part	Message/Artifact의 콘텐츠 단위. `text`(텍스트), `raw`(바이너리), `url`(외부 URI), `data`(구조화 JSON) 중 정확히 하나	`Part(root=TextPart(text="중요 메일 3통"))`
contextId	관련 Task/Message를 논리적으로 묶는 식별자 (서버 생성)	같은 메일 건에 대한 확인→알림 체인
TaskState	Task의 생애주기 상태: `submitted` → `working` → `completed` / `failed` / `canceled` / `rejected` + 중단 상태 `input-required` / `auth-required`	요청 접수(`submitted`) → 처리 중(`working`) → 완료(`completed`)

Client Agent와 Remote Agent — 역할은 고정이 아니다: 하나의 Agent가 상황에 따라 양쪽 역할을 모두 할 수 있습니다. 우리 실습에서 Check Agent는 외부 요청을 받을 때는 **Remote Agent**(서버)이지만, Notify Agent에게 알림을 요청할 때는 **Client Agent**(클라이언트)가 됩니다.

```
테스트 스크립트 ──A2A──▶ Check Agent ──A2A──▶ Notify Agent
 (Client Agent)     (Remote Agent이자      (Remote Agent)
                     Client Agent)
```

이 교재에서 "Client Agent"는 요청을 보내는 쪽, "Remote Agent"는 요청을 받는 쪽을 의미합니다.

A2A 현황 (RC v1.0 기준)

- 3가지 프로토콜 바인딩 (JSON-RPC / gRPC / REST)
- 서명된 보안 카드 (JWS/RFC 7515)
- 150+ 조직 채택
- Google이 Linux Foundation에 기부
- Python SDK: `a2a-sdk` (PyPI)

> 기준일: 위 내용은 **2026-02-23** 기준 요약입니다. 학습 전에는 `google/A2A` 릴리즈와 `a2a-sdk` 최신 버전을 함께 확인하세요.

블랙박스 원칙: A2A의 핵심 가치는 Agent의 내부 구현을 노출하지 않는 것입니다. 실제로 Tyson Foods와 Gordon Food Service는 A2A로 크로스컴퍼니 Agent 협업을 프로덕션에 적용했습니다 — 양사의 Agent가 서로의 내부 구현을 모른 채 Task만으로 협업합니다. (출처)

오늘 우리의 Check Agent ↔ Notify Agent도 같은 원리입니다: Check Agent는 "어떻게 메일을 확인하는지", Notify Agent는 "어떻게 알림을 보내는지" 서로 모릅니다.

A2A의 호출 흐름 — REST로 Agent를 부르는 방법

Agent는 자신의 정보를 **Agent Card**로 well-known URI에 게시합니다. 상대 Agent는 이 카드를 읽고 엔드포인트를 알아냅니다.

```
1) GET  https://notify.infra.com/.well-known/agent-card.json   ← 상대 발견
2) POST https://notify.infra.com/message:send                   ← 작업 요청
   → 응답: { "id": "task-123", "status": {"state": "working"} }
3) GET  https://notify.infra.com/tasks/task-123                 ← 결과 폴링
   → 응답: { "status": {"state": "completed"}, "artifacts": [...] }
```

REST 바인딩의 주요 엔드포인트 (스펙 §11.3):

동작	HTTP	URL
메시지 전송	`POST`	`/message:send`
스트리밍	`POST`	`/message:stream`
Task 조회	`GET`	`/tasks/{id}`
Task 목록	`GET`	`/tasks`
Task 취소	`POST`	`/tasks/{id}:cancel`
Task 구독	`POST`	`/tasks/{id}:subscribe`

> 콜론 표기법(`:send`, `:cancel`)은 Google API 디자인 가이드의 커스텀 메서드 규칙을 따릅니다. REST의 HTTP 동사(GET/POST/DELETE)만으로 표현하기 어려운 행위를 나타냅니다.

> **표기 규칙**: REST URL 경로에서는 콜론(`/message:send`)을, JSON-RPC의 `method` 필드에서는 슬래시(`message/send`)를 씁니다. 같은 동작이지만 프로토콜 바인딩에 따라 표기가 다릅니다. 이후 본문에서는 실습에서 사용하는 **JSON-RPC 표기(`message/send`)** 를 기본으로 씁니다.

동기 vs 비동기 — 네 가지 통신 패턴

A2A는 **동기와 비동기 모두 지원**합니다. `message/send` 요청의 `params.configuration.returnImmediately` 플래그로 전환합니다.

```json
{
  "method": "message/send",
  "params": {
    "message": { "role": "user", "parts": [{"text": "알림 보내줘"}] },
    "configuration": {
      "returnImmediately": false   // ← false(기본): 블로킹, true: 즉시 반환
    }
  }
}
```

또한 서버는 `message/send` 응답으로 **Task 대신 Message를 직접 반환**할 수도 있습니다. 단순한 질의응답(상태 추적 불필요)이면 Task를 생성하지 않고 Message로 즉시 응답합니다.

패턴	메서드	동작 방식	적합한 상황
블로킹	`message/send` (`returnImmediately: false`)	완료까지 대기 후 결과 반환	빠르게 끝나는 작업
폴링	`message/send` (`returnImmediately: true`) + `tasks/get`	즉시 반환, 클라이언트가 주기적 조회	수 초~수 분 작업
스트리밍	`message/stream` (SSE)	서버가 실시간으로 진행 상황 푸시	실시간 피드백 필요
웹훅	`message/send` + `pushNotificationConfig`	서버가 완료 시 클라이언트 URL에 POST	수 분~수 시간 작업

오늘 실습에서는 `message/send`를 호출하고 응답을 바로 받는 단순한 구조를 사용합니다. `returnImmediately`를 명시하지 않으므로 기본값(`false`, 블로킹)으로 동작합니다.

> 출처: A2A Streaming & Async, Life of a Task

순환 호출 문제 — A2A 스펙의 알려진 한계

Agent A → B → C → A처럼 순환 호출이 발생하면 어떻게 될까요?

A2A 프로토콜 자체에는 순환 호출 방지 메커니즘이 없습니다. HTTP의 `Max-Forwards`나 분산 추적의 span depth 같은 hop counter가 스펙에 정의되어 있지 않습니다. Traceability Extension이 `parent_step_id`로 호출 체인을 기록하지만, 이는 관측(observability)용이지 런타임 차단은 아닙니다.

따라서 **실무에서는 애플리케이션 레벨에서 직접 방어**해야 합니다:

방법	설명
hop counter	`metadata`에 커스텀 필드로 호출 깊이를 전달, 임계치 초과 시 `REJECTED` 반환
DAG 검증	오케스트레이터가 Agent 호출 그래프를 배포 시점에 DAG(비순환 방향 그래프)로 검증
Task 타임아웃	클라이언트 측 HTTP 타임아웃 설정 (Python SDK: `A2AClientTimeoutError`)
REJECTED 상태	Agent가 이미 처리 중인 `contextId`의 재진입 요청을 거부

오늘 실습의 Check → Notify 구조는 **단방향**이므로 순환이 발생하지 않습니다. 하지만 프로덕션에서 다수의 Agent를 연결할 때는 반드시 고려해야 할 사항입니다.

> 순환 호출 방지는 A2A 스펙에 명시적으로 다루어지지 않으며, 위 대응 방법은 분산 시스템의 일반적인 방어 패턴입니다. A2A 보안 전반(Agent Card 스푸핑, 프롬프트 인젝션, OAuth 취약점 등)에 대해서는 Semgrep: A Security Engineer's Guide to A2A를 참고하세요.

Checkpoint: A2A 핵심 개념 확인

1. MCP는 Agent→Tool(수직), A2A는 Agent↔Agent(수평)입니다. Notify Agent가 Slack API에 접근할 때는 MCP와 A2A 중 어떤 프로토콜을 사용할까요?
2. Agent Card에는 "이 Agent가 **누구**이고, **무엇**을 할 수 있고, **어디**로 접근하는지"를 담습니다. 이 세 가지에 해당하는 필드를 각각 말해 보세요. (힌트: 위 개념 테이블과 Agent Card JSON 예시를 참고하세요)
3. Check Agent가 Notify Agent에게 작업을 요청하면, Notify Agent가 처리 중일 때 Task의 상태는 무엇일까요? 처리가 끝나면 어떤 상태로 바뀔까요?
4. `message/send`에서 `returnImmediately: true`로 설정하면 동작이 어떻게 달라지나요?

먼저 직접 생각한 뒤, 아래 정답을 확인하세요.

정답:

1. **MCP**. Slack API는 "도구/데이터"이므로 Agent→Tool 수직 연결(MCP). Agent끼리 협업할 때만 A2A.
2. **name**(누구인지), **skills**(무엇을 할 수 있는지), **supportedInterfaces**(어디로 접근하는지). 이 외에도 `description`, `version`, `capabilities`, `defaultInputModes`, `defaultOutputModes`까지 총 8개가 필수 필드입니다. (스펙 §4.4.1 AgentCard)
3. 처리 중에는 `working`, 완료되면 `completed`. 이 외에도 `failed`, `canceled`, `rejected`(거부), `input-required`(추가 입력 필요), `auth-required`(인증 필요) 상태가 있습니다.
4. 서버가 **Task 완료를 기다리지 않고 즉시 Task ID만 반환**합니다(비동기). 클라이언트는 `tasks/get`으로 폴링하여 결과를 가져옵니다. 기본값(`false`)이면 완료까지 블로킹합니다(동기).

⏱ 16:23

실습 1: Agent Card 작성 (10분)

> 📂 실습 코드: `ch5-a2a/agent_cards/`
>
> ▶ 확인: (Agent Card JSON 파일 확인)

```
ls ch5-a2a/agent_cards/
```

Agent Card란?

Agent Card는 Agent의 **자기소개서**입니다. 다른 Agent가 이 카드를 읽고 "이 Agent가 무엇을 할 수 있는지" 판단합니다.

Check Agent의 Agent Card

```
{
  "name": "Mail Check Agent",
  "description": "메일함을 확인하고 중요 메일을 감지합니다",
  "version": "1.0.0",
  "supportedInterfaces": [
    {"url": "http://localhost:9501", "protocolBinding": "JSONRPC", "protocolVersion": "1.0"}
  ],
  "capabilities": { "streaming": false },
  "defaultInputModes": ["text/plain"],
  "defaultOutputModes": ["text/plain"],
  "skills": [
    {
      "id": "check-mail",
      "name": "메일 확인",
      "description": "메일함을 확인하고 중요 메일을 필터링합니다"
    }
  ]
}
```

Notify Agent의 Agent Card

```
{
  "name": "Notify Agent",
  "description": "알림을 전송합니다 (슬랙, 콘솔 등)",
  "version": "1.0.0",
  "supportedInterfaces": [
    {"url": "http://localhost:9502", "protocolBinding": "JSONRPC", "protocolVersion": "1.0"}
  ],
  "capabilities": { "streaming": false },
  "defaultInputModes": ["text/plain"],
  "defaultOutputModes": ["text/plain"],
  "skills": [
    {
      "id": "send-notification",
      "name": "알림 전송",
      "description": "중요 메일에 대한 알림을 슬랙이나 콘솔로 전송합니다"
    }
  ]
}
```

> 위 JSON에는 스펙상 필수 필드 8개(`name`, `description`, `version`, `supportedInterfaces`, `capabilities`, `defaultInputModes`, `defaultOutputModes`, `skills`)가 모두 포함되어 있습니다. 실습 코드(`ch5-a2a/agent_cards/`)에는 `tags`, `examples` 등 선택 필드도 추가되어 있으니 함께 확인하세요.

발견 경로

A2A 스펙은 Agent를 발견하는 **3가지 전략**을 정의합니다.

전략	방식	적합한 상황
Well-Known URI	`/.well-known/agent-card.json`에 게시 (RFC 8615)	공개 Agent, 도메인 기반 발견
큐레이션 레지스트리	중앙 카탈로그 서비스가 Agent Card를 색인, 능력 기반 검색	기업 내부 Agent 마켓플레이스
직접 설정	설정 파일·환경변수에 Agent URL 하드코딩	개발 환경, 고정된 Agent 관계

오늘 실습에서는 가장 기본인 **Well-Known URI** 방식을 사용합니다. 실습 2에서 서버를 띄운 뒤 아래 URL로 직접 확인할 수 있습니다.

```
http://localhost:9501/.well-known/agent-card.json  → Check Agent Card
http://localhost:9502/.well-known/agent-card.json  → Notify Agent Card
```

지금은 서버를 띄우기 전이므로, JSON 파일을 직접 열어 구조를 확인합니다:

```
uv run python3 -c "
import json
card = json.load(open('ch5-a2a/agent_cards/check_agent.json'))
print(card['name'])
print(card['supportedInterfaces'][0]['url'])
print(card['skills'][0]['id'])
"
```

완료 기준:

1. Agent Card JSON에서 필수 8개 필드(`name` , `description` , `version` , `supportedInterfaces` , `capabilities` , `defaultInputModes` , `defaultOutputModes` , `skills`)를 식별할 수 있다.
2. `supportedInterfaces[0].url` 이 해당 Agent의 실행 포트와 일치한다.
3. `skills[].id` 가 Agent의 역할을 반영하는 값이다.

> **Agent Card를 직접 작성해 볼까요? (5분)**
>
> `ch5-a2a/notebooks/a2a_fill_in_blank.ipynb` 을 열고 **실험 1**을 진행하세요.
>
> Agent Card의 `name` , `url` , `skills` 빈칸을 채우고, 필수 필드가 갖춰진 Card를 구성합니다.

⏱ 16:33

실습 2: Check Agent 구현 (17분)

> 📂 실습 코드: `ch5-a2a/check_agent.py`
>
> ▶ 실행:

```
uv run python3 ch5-a2a/check_agent.py
```

> 서버가 기동되면 실습 1에서 확인한 Agent Card를 실제로 조회해 봅니다:

```
curl -s http://localhost:9501/.well-known/agent-card.json | uv run python3 -c "import sys,json;
print(json.dumps(json.load(sys.stdin),indent=2,ensure_ascii=False))"
```

> 200 응답과 함께 `name` , `url` , `skills[].id` 가 출력되면 정상입니다.

a2a-sdk 설치

```
uv add "a2a-sdk[http-server]" uvicorn
```

Check Agent 서버

```
from a2a.server.apps import A2AStarletteApplication
from a2a.server.agent_execution import AgentExecutor, RequestContext
from a2a.server.request_handlers import DefaultRequestHandler
from a2a.server.tasks import InMemoryTaskStore
from a2a.server.tasks.task_updater import TaskUpdater
from a2a.server.events import EventQueue
from a2a.types import AgentCard, AgentCapabilities, AgentSkill, Part, TextPart
import uvicorn

class CheckAgentExecutor(AgentExecutor):
    async def execute(self, context: RequestContext, event_queue: EventQueue):
        """메일을 확인하고 중요 메일을 감지합니다."""
```

```
        # TaskUpdater: taskId/contextId/artifactId/final 등을 자동 관리
        updater = TaskUpdater(
            event_queue=event_queue,
            task_id=context.task_id,
            context_id=context.context_id,
        )

        # 1. 메일 확인 (모킹)
        emails = [
            {"from": "팀장님", "subject": "긴급: 서버 점검", "important": True},
            {"from": "HR팀", "subject": "워크숍 일정", "important": False},
            {"from": "고객사", "subject": "프로젝트 미팅", "important": True},
        ]
        important = [e for e in emails if e["important"]]

        # 2. 결과를 Artifact로 전달 - artifactId 자동 생성
        report = f"중요 메일 {len(important)}통 감지:\n"
        for e in important:
            report += f"  - [{e['from']}] {e['subject']}\n"

        await updater.add_artifact(
            parts=[Part(root=TextPart(text=report))],
            name="mail-check-report",
        )
        # 3. 완료 - final=True, Message 객체 모두 자동 처리
        await updater.complete(
            message=updater.new_agent_message(
                parts=[Part(root=TextPart(text="메일 확인 완료"))],
            ),
        )

# Agent Card 정의
agent_card = AgentCard(
    name="Mail Check Agent",
    description="메일함을 확인하고 중요 메일을 감지합니다",
    url="http://localhost:9501",
    version="1.0.0",
    capabilities=AgentCapabilities(streaming=False),
    skills=[AgentSkill(
        id="check-mail",
        name="메일 확인",
        description="메일함을 확인하고 중요 메일을 필터링합니다",
    )],
)

def create_app():
    executor = CheckAgentExecutor()

    # InMemoryTaskStore: A2A Task의 상태(submitted→working→completed)를
    # 메모리에 저장하여 task/get 조회 시 진행 상황을 반환합니다.
    handler = DefaultRequestHandler(
        agent_executor=executor,
        task_store=InMemoryTaskStore(),
    )
    application = A2AStarletteApplication(
        agent_card=agent_card,
        http_handler=handler,
    )
    return application.build()

if __name__ == "__main__":
    uvicorn.run(create_app(), host="0.0.0.0", port=9501)
```

> `TaskUpdater` — **이벤트 발행 헬퍼:** `TaskStatusUpdateEvent` 나 `TaskArtifactUpdateEvent` 를 직접 생성하면 `taskId`, `contextId`, `final`, `artifactId`, `messageId` 등 필수 필드를 매번 채워야 합니다. `TaskUpdater` 는 이를 자동화합니다 — 생성 시 `context.task_id` 와

> `context.context_id`를 한 번만 전달하면, 이후 `start_work()`, `add_artifact()`, `complete()`, `cancel()` 등의 메서드가 모든 필드를 자동으로 채웁니다. `new_agent_message()`는 `role=agent`, `messageId=UUID`가 세팅된 `Message` 객체를 만들어줍니다.

> **왜 LLM을 사용하지 않나요?** 이 실습의 Check Agent와 Notify Agent는 의도적으로 LLM 없이 규칙 기반으로 동작합니다. 메일 필터링(`important: True/False`)과 알림 전송은 LLM이 필요 없는 결정적(deterministic) 작업이고, LLM 없이 구현해야 **A2A 프로토콜 자체의 구조**(Agent Card, JSON-RPC, Task 상태 흐름)에 집중할 수 있습니다. 프로덕션에서 LLM 기반 메일 분류가 필요하다면, `CheckAgentExecutor.execute()` 안에서 LLM을 호출하면 됩니다 — A2A 서버 구조는 그대로 유지됩니다.

> **스펙 vs SDK 차이:** 스펙(RC v1.0)에서는 `supportedInterfaces` 배열이 필수이지만, `a2a-sdk` v0.3.25는 아직 이 필드를 구현하지 않아 `url=` + `preferredTransport`로 직렬화합니다. 따라서 Python 코드에서는 `url=`을 사용하고, 정적 JSON 파일(`agent_cards/*.json`)은 스펙 기준 `supportedInterfaces`로 작성합니다. SDK가 스펙을 따라잡으면 코드도 `supportedInterfaces`로 전환될 예정입니다.

Check Agent → Notify Agent A2A 호출 (핵심 발췌)

Check Agent는 **Remote Agent**(서버)이지만, Notify Agent를 호출할 때는 **Client Agent** 역할도 합니다. 알림 전송 결과는 Check Agent의 보고서에 포함되어 원래 요청한 Client Agent에게 반환됩니다.

```
Client Agent → Check Agent(Remote) → Notify Agent(Remote)
                                      ↓ 알림 전송
                    보고서에 포함 ⟵ 결과 반환
Client Agent ← 최종 보고서
```

아래는 `check_agent.py`에서 이 호출을 담당하는 핵심 부분입니다. JSON-RPC 구조를 직접 보여주기 위해 httpx로 구현했습니다.

```python
# check_agent.py — Notify Agent A2A 호출 (발췌, 전체는 실습 파일 참고)
NOTIFY_AGENT_URL = "http://localhost:9502"

async def notify_agent_via_a2a(important_emails: list[dict]) -> str:
    """Notify Agent에게 알림을 위임하고, 결과를 보고서용 문자열로 반환합니다."""
    # 중요 메일 요약 텍스트 구성
    email_summary = [f"- [{e['sender_name']}] {e['subject']}" for e in important_emails]
    notification_text = f"중요 메일 {len(important_emails)}통이 감지되었습니다!\n" + "\n".join(email_summary)

    # A2A JSON-RPC 요청 구성
    a2a_request = {
        "jsonrpc": "2.0",
        "id": "check-to-notify-001",
        "method": "message/send",          # A2A 메시지 전송 메서드
        "params": {
            "message": {
                "role": "user",
                "parts": [{"kind": "text", "text": notification_text}],
            },
        },
    }

    async with httpx.AsyncClient(timeout=10.0) as client:
        response = await client.post(f"{NOTIFY_AGENT_URL}/", json=a2a_request)
        result = response.json()
    return f"알림 전송 완료: {result.get('result', {}).get('status', {}).get('state', 'unknown')}"
```

`CheckAgentExecutor.execute()` 안에서 중요 메일이 있으면 이 함수를 호출합니다. 위 코드는 JSON-RPC 구조를 직접 보여주기 위해 httpx로 작성했습니다. SDK `ClientFactory`를 사용하는 간결한 방식은 아래 "Client Agent 코드" 섹션과 `check_and_notify_client.py`를 참고하세요.

⏱ 16:50

실습 3: Notify Agent 구현 및 연동 (13분)

> 📁 실습 코드: `ch5-a2a/notify_agent.py`
>
> ▶ 실행: (별도 터미널에서)

```
uv run python3 ch5-a2a/notify_agent.py
```

Notify Agent 서버

```
class NotifyAgentExecutor(AgentExecutor):
    async def execute(self, context: RequestContext, event_queue: EventQueue):
        """알림을 전송합니다."""
        updater = TaskUpdater(
            event_queue=event_queue,
            task_id=context.task_id,
            context_id=context.context_id,
        )

        # 1. 메시지 추출 - Part.root가 TextPart인 것만 필터링
        message = ""
        if context.message and context.message.parts:
            message = "".join(
                part.root.text for part in context.message.parts
                if isinstance(part.root, TextPart)
            )

        # 2. 콘솔 알림 (실제로는 Slack API 호출)
        print(f"\n{'='*50}")
        print(f"  알림 전송! 내용: {message}")
        print(f"{'='*50}\n")

        # 3. 결과를 이벤트로 전달 - TaskUpdater가 ID/상태 자동 관리
        await updater.add_artifact(
            parts=[Part(root=TextPart(text="알림 전송 완료"))],
        )
        await updater.complete(
            message=updater.new_agent_message(
                parts=[Part(root=TextPart(text="알림 전송 완료"))],
            ),
        )
```

텍스트 추출 패턴 — `Part.root` 는 `TextPart | FilePart | DataPart` 중 하나이므로, `isinstance` 로 `TextPart` 만 필터링합니다:

```
from a2a.types import TextPart

# context.message.parts에서 텍스트만 추출
text = "".join(
    part.root.text for part in context.message.parts
    if isinstance(part.root, TextPart)
)
```

왜 Part라는 단위가 필요한가? A2A 메시지는 텍스트만 주고받는 것이 아닙니다. 하나의 메시지에 여러 종류의 데이터를 함께 담을 수 있도록 Part 배열로 설계되어 있습니다:

Part 타입	용도	예시
`TextPart`	자연어 텍스트	보고서, 요약, 응답 메시지
`FilePart`	바이너리 파일 또는 URL	이미지, PDF, 파일 링크
`DataPart`	JSON 구조화 데이터	API 응답, 메타데이터, 통계

예를 들어 이미지 분석 Agent가 결과를 반환할 때, 텍스트 설명(`TextPart`) + 원본 이미지(`FilePart`) + 분석 수치(`DataPart`)를 하나의 메시지에 담을 수 있습니다. 이메일의 본문과 첨부파일의 관계와 유사합니다. 우리 실습에서는 `TextPart` 만 사용하지만, 이 구조 덕분에 A2A는 멀티모달 Agent 간 통신도 지원합니다.

스트리밍의 경우: Agent Card에서 `capabilities.streaming: true` 로 선언한 Remote Agent는 `message/stream` 메서드를 지원합니다. 이때 Remote Agent는 `TaskUpdater` 의 메서드(`start_work()` , `add_artifact()` , `complete()`)로 이벤트를 하나씩 큐에 넣고, SDK가 이를 SSE(Server-Sent Events)로

Client Agent에 실시간 전달합니다. Client Agent는 `TaskStatusUpdateEvent`(상태 변화)와 `TaskArtifactUpdateEvent`(결과 조각)를 순서대로 수신합니다.

```
[스트리밍 흐름]
Remote Agent: updater.start_work(...)              → SSE → Client Agent
Remote Agent: updater.add_artifact(1차 결과)        → SSE → Client Agent
Remote Agent: updater.add_artifact(2차 결과)        → SSE → Client Agent
Remote Agent: updater.complete(...)                → SSE → Client Agent
```

`TaskUpdater.add_artifact(append=True)`로 설정하면 이전 Artifact에 Part를 이어붙이고, `last_chunk=True`로 스트리밍 종료를 알립니다. 우리 실습에서는 `streaming=False`이므로 `message/send` 한 번의 요청-응답으로 완료되지만, 서버 측 코드 구조(`TaskUpdater`)는 스트리밍/비스트리밍 모두 동일합니다 — SDK가 전송 방식만 바꿔줍니다.

Client Agent: 누가 Agent에게 일을 맡기는가?

Check Agent와 Notify Agent는 A2A **Remote Agent**(서버)입니다. Remote Agent는 스스로 동작하지 않고, 누군가 요청을 보내야 일을 시작합니다. 이 "누군가"가 **Client Agent**입니다.

실제 환경에서 Client Agent가 될 수 있는 것:

- 사용자가 직접 실행하는 테스트 스크립트
- 매 30분마다 메일을 확인하는 스케줄러(cron)
- 상위 오케스트레이터 Agent (예: Elasticsearch 사례의 News Chief)

우리 실습에서는 `check_and_notify_client.py`가 Client Agent 역할을 합니다. 이 스크립트는 **Check Agent에게만 요청**합니다. Notify Agent 호출은 Check Agent가 내부적으로 처리합니다 — 이것이 "하나의 Agent가 Remote이자 Client 역할을 겸한다"의 실제 동작입니다.

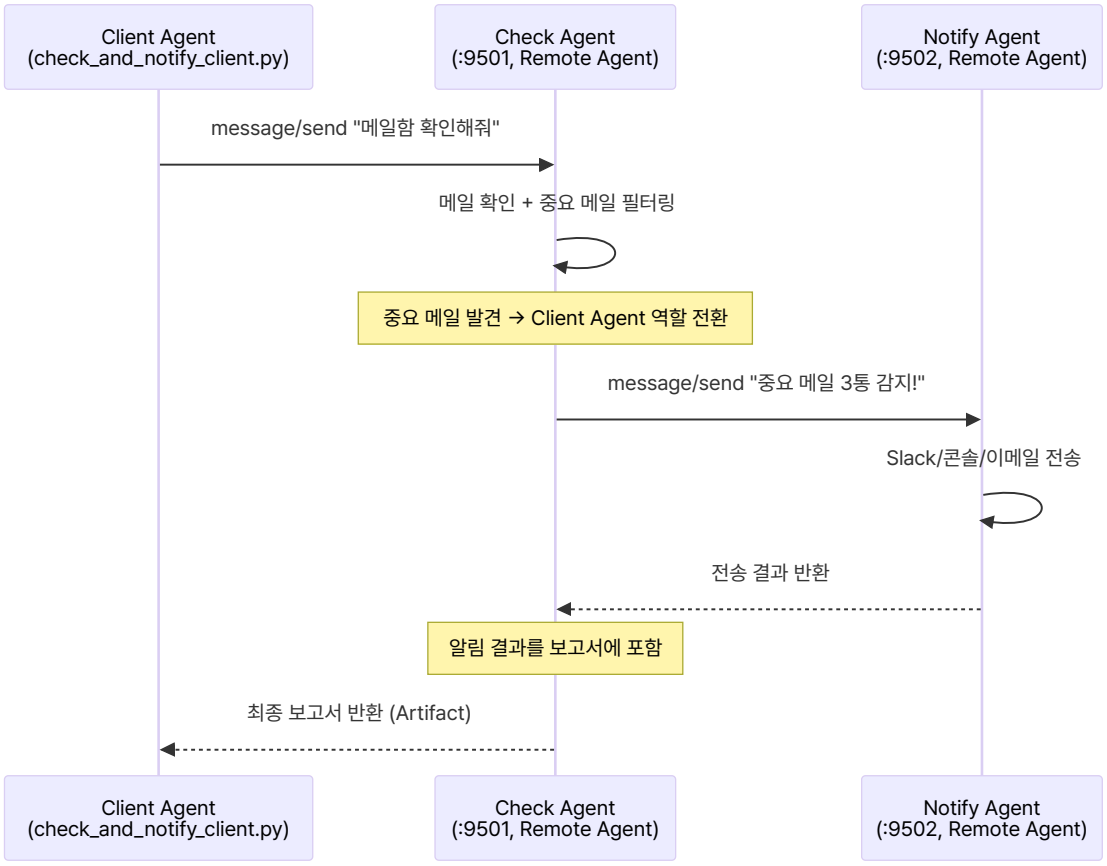

Client Agent 코드 — ClientFactory + Client 사용

`check_and_notify_client.py`(Client Agent)에서는 `a2a-sdk`의 `ClientFactory`를 사용합니다. Check Agent에게만 요청을 보내면 되므로 코드가 간결합니다. 앞서 `check_agent.py`에서 httpx로 JSON-RPC를 직접 구성하는 방식을 봤으므로, 여기서는 SDK가 이를 어떻게 추상화하는지 비교합니다.

```python
# check_and_notify_client.py (핵심 발췌)
from a2a.client import A2ACardResolver, ClientFactory, ClientConfig
from a2a.types import Message, Part, TextPart, Role

CHECK_AGENT_URL = "http://localhost:9501"
```

```python
async def call_check_agent(message_text: str):
    async with httpx.AsyncClient(timeout=30.0) as httpx_client:
        # 1) Agent Card 조회
        resolver = A2ACardResolver(httpx_client=httpx_client, base_url=CHECK_AGENT_URL)
        card = await resolver.get_agent_card()

        # 2) Client 생성 — Agent Card의 transport 정보로 자동 구성
        factory = ClientFactory(config=ClientConfig(httpx_client=httpx_client, streaming=False))
        client = factory.create(card=card)

        # 3) Message 생성 + 전송
        msg = Message(
            role=Role.user,
            messageId=str(uuid.uuid4()),
            parts=[Part(root=TextPart(text=message_text))],
        )
        async for event in client.send_message(request=msg):
            print(event)  # Task/Message 이벤트 수신
```

httpx 직접 방식(`check_agent.py` 의 `notify_agent_via_a2a`)과 비교하면:

- `jsonrpc`, `method`, `params` 구성 → SDK가 자동 처리
- Agent Card 조회 → `A2ACardResolver`가 `/.well-known/agent-card.json` 자동 접근
- 응답 파싱 → 이벤트 스트림으로 `Task` / `Message` 객체 수신

실행 방법

3개 터미널을 순서대로 실행합니다. 각 서버(Remote Agent)가 정상 기동된 것을 확인한 뒤 다음 단계로 넘어가세요.

```bash
# 터미널 1: Check Agent (Remote Agent) 실행
uv run python3 ch5-a2a/check_agent.py
# ✅ 정상: "서버 시작 중..." 로그 출력 후 대기 상태

# 터미널 2: Notify Agent (Remote Agent) 실행
uv run python3 ch5-a2a/notify_agent.py
# ✅ 정상: "서버 시작 중..." 로그 출력 후 대기 상태

# 터미널 3: Client Agent로 테스트 (터미널 1, 2가 대기 상태인 것을 확인한 후)
uv run python3 ch5-a2a/check_and_notify_client.py
# → Check Agent에게 요청 → Check Agent가 내부적으로 Notify Agent 호출
# → 최종 보고서에 알림 전송 결과가 포함되어 반환
```

> 터미널 1, 2의 서버가 완전히 기동되기 전에 터미널 3을 실행하면 `ConnectionRefusedError`가 발생합니다. `curl`로 Agent Card 응답을 먼저 확인하세요.

> **httpx 직접 vs A2AClient 비교:** `check_agent.py`(Remote Agent 내부)의 `notify_agent_via_a2a()`는 httpx로 JSON-RPC를 직접 구성하여 프로토콜 구조를 학습합니다. `check_and_notify_client.py`(Client Agent)는 `A2AClient` SDK를 사용하여 동일한 호출을 간결하게 수행합니다. 프로덕션에서는 `A2AClient`를 권장합니다.

정상 동작 체크포인트:

1. **터미널 3 출력**: Client Agent가 Check Agent의 최종 보고서를 수신하고, "알림 전송 완료" 메시지 포함
2. **터미널 1 로그**: Check Agent가 Notify Agent를 호출하는 로그 ("Notify Agent에게 알림 요청...")
3. **터미널 2 로그**: Notify Agent에 `[SLACK 알림 시뮬레이션]` 및 `[콘솔 알림]` 출력

완료 기준:

1. Client Agent → Check Agent → Notify Agent 전체 체인이 하나의 요청으로 동작한다.
2. Notify Agent가 미실행 상태일 때 Check Agent가 "알림 전송 실패"를 보고서에 포함하여 반환한다.

A2A 메시지 구조를 추적해 볼까요? (5분)

`ch5-a2a/notebooks/a2a_fill_in_blank.ipynb` 을 열고 **실험 2**를 진행하세요.

Check Agent가 Notify Agent에게 보내는 A2A JSON-RPC 메시지의 `method`, `role`, `parts` 빈칸을 채우며 메시지 구조를 직접 구성해 봅니다.

⏱ 17:03

A2A 통신 흐름 — 실습 코드 기준 (7분)

아래 다이어그램은 **우리 실습 코드가 실제로 수행하는 흐름**입니다. Check Agent의 메일 데이터와 Notify Agent의 알림 채널은 A2A 프로토콜 구조에 집중하기 위해 모킹(콘솔 출력)으로 구현되어 있습니다.

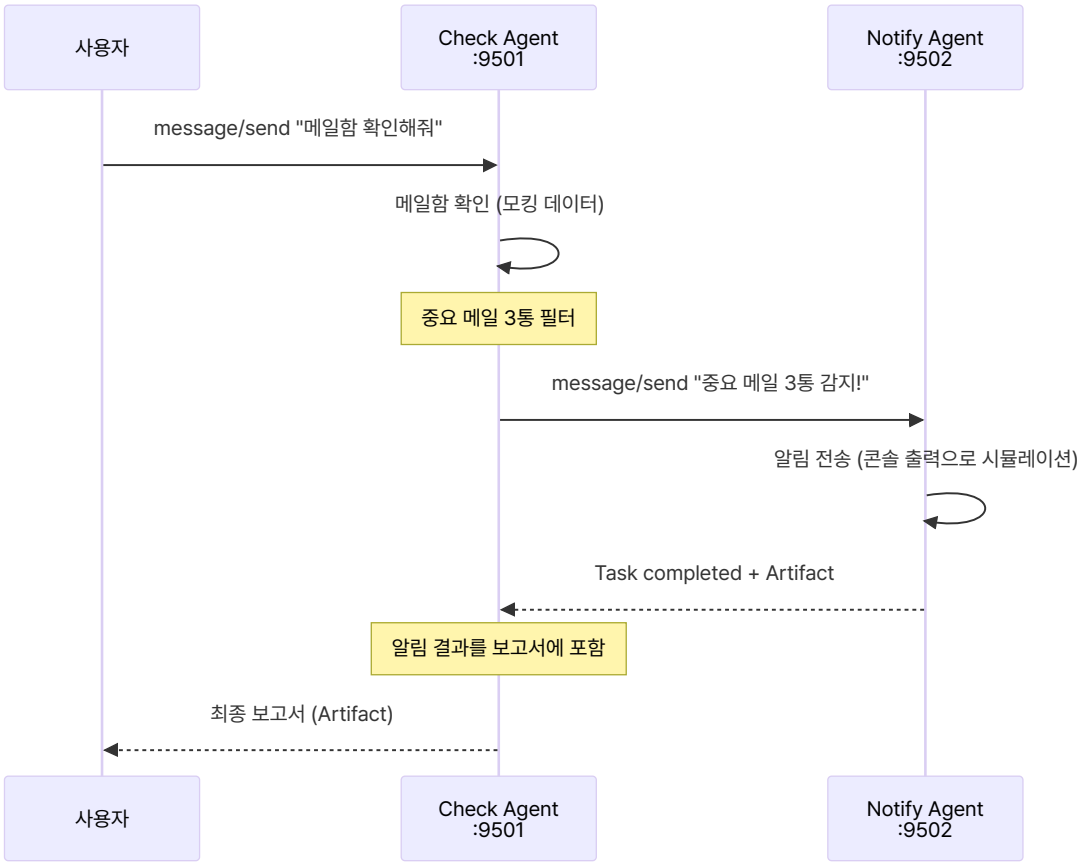

프로덕션에서는 Check Agent가 **MCP로 실제 메일 서버**에 접근하고, Notify Agent가 **MCP로 Slack API**를 호출합니다. 이 구조에서도 **Agent 간 통신(A2A)은 동일**합니다 — 달라지는 것은 각 Agent의 내부 구현뿐입니다. 이것이 A2A의 **블랙박스 원칙**입니다.

블랙박스 원칙을 확인해 볼까요? (3분)

`notify_agent.py` 의 `NotificationChannel` 클래스를 열어보세요.

1. `send_slack()`, `send_console()`, `send_email_mock()` — 세 메서드 모두 실제로는 **콘솔 출력**입니다. 이 "내부 구현"을 실제 Slack API 호출로 교체해도 Check Agent 코드는 바뀌지 않습니다. **왜 그럴까요?**
2. `NotifyAgentExecutor.execute()` 안에서 알림 채널을 호출하는 부분을 찾으세요. 이 부분만 수정하면 새 채널(예: MS Teams)을 추가할 수 있습니다. **Check Agent나 Client Agent에는 어떤 변경이 필요할까요?** (정답: 없음 — A2A 인터페이스가 동일하므로)

A2A 역할 전환을 추적해 볼까요? (5분)

`ch5-a2a/notebooks/a2a_fill_in_blank.ipynb` 을 열고 **실험 3**을 진행하세요.

Client Agent → Check Agent → Notify Agent 체인에서, 각 구간의 Client/Remote 역할을 빈칸으로 채우며 "하나의 Agent가 양쪽 역할을 겸한다"는 개념을 확인합니다.

⏱ 17:08

핵심 요약

개념	설명
A2A	Agent 간 수평 통신 프로토콜 (Task 기반)
MCP	Agent→Tool 수직 연결 프로토콜 (Tool Call 기반)
Agent Card	Agent의 자기소개서 (이름, 설명, 능력, 엔드포인트 등 8개 필수 필드)
Task	Agent에게 보내는 작업 요청 단위
역할 분리	Check Agent = 감지, Notify Agent = 알림

```
전체 그림:
  DeepAgents (Harness)
    └ Skills (절차적 지식)
    └ MCP (데이터 접근)
    └ A2A (Agent 간 협업)   ← 오늘 추가!
```

> **다음 Chapter**: 모든 것을 하나로 연결하는 통합 데모와 Wrap-up.

⏱ 17:10~17:15 쉬는 시간

실습 트러블슈팅 (FAQ)

Q1. `uv add a2a-sdk` 가 실패합니다.

- 버전을 명시하세요: `uv add "a2a-sdk>=0.3,<1.0"`
- 또는 `uv pip install -r code/requirements.txt` 로 전체 의존성을 설치하세요.

Q2. `ConnectionRefusedError` 가 발생합니다.

- 해당 포트의 Agent 서버가 아직 기동되지 않았습니다.
- `curl -s http://localhost:9501/.well-known/agent-card.json` 으로 서버 상태를 먼저 확인하세요.
- Check Agent(9501) → Notify Agent(9502) → Client 순서로 실행하세요.

Q3. Agent 서버가 시작 직후 종료됩니다.

- 포트가 이미 사용 중일 수 있습니다: `lsof -i :9501` 또는 `lsof -i :9502`
- 기존 프로세스를 종료하거나 다른 포트를 사용하세요.
- Python 3.10 미만이면 `a2a-sdk` 호환 문제가 있을 수 있습니다.

Q4. Check Agent → Notify Agent 호출이 타임아웃됩니다.

- `check_agent.py` 의 Notify Agent 호출은 `timeout=10.0` 입니다.
- Notify Agent(9502)가 정상 실행 중인지 확인하세요.
- Notify Agent 없이 Check Agent만 단독 실행해도 메일 확인 기능은 정상 동작합니다. 알림 전송만 실패로 표시됩니다.

Q5. 이전에 실행한 서버가 죽지 않아 포트 충돌이 납니다.

- `Ctrl+C` 로 서버를 종료합니다.
- 백그라운드에 남아있다면: `kill $(lsof -ti :9501)` 및 `kill $(lsof -ti :9502)`

심화: 분산 협업 안정성 기준

분산시스템 기본 규약

항목	기본값
timeout	10s (외부 Agent 호출)
retry	최대 2회
backoff	1s → 2s (지수 증가)

항목	기본값
idempotency key	`message_id` 재사용으로 중복 처리 방지

Agent Card를 Contract로 관리

필수 계약 항목:

1. 입력 메시지 스키마(`parts` 포맷)
2. 출력/result 스키마(성공/실패 구조)
3. 오류 코드 정책(예: `A2A_TIMEOUT`, `A2A_INVALID_REQUEST`)
4. 버전 정책(major/minor, 하위 호환 규칙)

협업 품질 지표 (실습 과제)

지표	정의
핸드오프 성공률	Check → Notify 전달 성공 비율
평균 처리시간	요청~최종 Artifact까지 소요 시간
재시도율	전체 요청 중 retry 발생 비율

참고 자료

- A2A Protocol 공식
- a2a-sdk (Python)
- A2A vs MCP 비교
- Google ADK A2A 통합
- Elasticsearch A2A+MCP Newsroom
- Gordon Food Service Case Study
- Linux Foundation AAIF (A2A+MCP 공동 거버넌스)
- A2A 프로토콜 v0.3 업그레이드 — gRPC 지원, 150+ 기업 채택
- Google의 A2A Linux Foundation 기부 — 벤더 중립 거버넌스
- A2A Protocol 공식 사이트
- ACP joins forces with A2A under Linux Foundation (LF AI & Data, 2025) — ACP↔A2A 통합
- IBM Think: Agent Communication Protocol — ACP 설계 철학, A2A 통합 배경
- A2A RC v1.0 Specification — REST/gRPC/JSON-RPC 3가지 바인딩 스펙
- A2A: Streaming & Asynchronous Operations — 동기/비동기/SSE/웹훅 패턴
- A2A: Life of a Task — Task 상태 머신, Message vs Task 응답
- A2A: Agent Discovery — Well-Known URI, 큐레이션 레지스트리, 직접 설정 3가지 발견 전략
- A2A: Key Concepts — Core Actors, Part 타입, Message 구조
- Semgrep: A Security Engineer's Guide to A2A — Agent Card 스푸핑, OAuth, 프롬프트 인젝션 등 보안 분석